

Clase 1: Data Pipelines y ETL

Módulo 7: Data Pipelines y plataformas de visualización

Claudio Torres Fonseca

mail: `claudio.torresf@usm.cl`

Universidad de Santiago de Chile

Diplomado en Data Engineer
2026

Contenido

- 1 Introducción a los Data Pipelines
- 2 El Proceso ETL (Extract, Transform, Load)
- 3 Herramientas y ELT

Caso de Uso: Centralización de Ventas Regionales

El desafío del crecimiento en LATAM

Escenario

Nuestra empresa de Retail/E-commerce se ha expandido con éxito y opera activamente en tres mercados: **Chile (Santiago)**, **Perú (Lima)** y **Argentina (Buenos Aires)**. Cada país registra sus transacciones de forma independiente.

Caso de Uso: Centralización de Ventas Regionales

El desafío del crecimiento en LATAM

Problemática

- **Santiago:** Guarda las ventas en una base de datos relacional tradicional (PostgreSQL) en tiempo real.
- **Lima:** Genera un archivo consolidado en un servidor local (CSV/Parquet) al cierre de cada jornada (Batch).
- **Buenos Aires:** Utiliza un sistema legacy que expone las transacciones únicamente a través de una API REST con cuotas limitadas de consumo.

El Gran Dolor de la Gerencia:

El Directorio necesita un reporte unificado en Dólares (USD) a primera hora de la mañana para analizar el rendimiento regional, detectar anomalías y tomar decisiones de inventario.

Caso de Uso: Centralización de Ventas Regionales

Preguntas (1/3)

- Tenemos una base de datos, un archivo plano y una API.
 - ¿Qué problemas conceptuales o técnicos ven si intentamos conectar la herramienta de visualización (ej. Looker o Tableau) directamente a estas tres fuentes al mismo tiempo?

Caso de Uso: Centralización de Ventas Regionales

Preguntas (2/3)

- Cada país vende en su moneda local (CLP, PEN, ARS). Si corremos un proceso que extrae los datos y se cae a la mitad por culpa de la API de Buenos Aires,
 - ¿Qué pasa si lo volvemos a correr?
 - ¿Duplicaremos las ventas de Santiago que ya se habían cargado?

Caso de Uso: Centralización de Ventas Regionales

Preguntas (3/3)


- ¿Quién debe resolver este desorden de formatos, asegurar que los datos lleguen limpios, transformados a USD, centralizarlos y dejarlos listos para el negocio a las 8:00 AM?

Ciclo de vida de la Ingeniería de Datos

Definición

El ciclo de vida comprende las etapas que convierten los datos sin procesar en un producto final útil, listo para el consumo.

Ciclo de vida de la Ingeniería de Datos




¿Qué es un data pipeline?

Definición

Un **Data Pipeline** es el conjunto de arquitectura, procesos y sistemas encargados de transportar y transformar los datos desde su origen hasta su destino.

- **Flujo Operacional:** Conecta las fuentes con los destinos mediante la ejecución secuencial de tareas técnicas (filtros, agregaciones, limpieza y fusión de datos).
- **Visión Estratégica:** Soporta de forma robusta las distintas etapas del ciclo de vida de la ingeniería de datos.
- **Flexibilidad:** Está diseñado para ser altamente adaptable a los cambios y necesidades evolutivas de la infraestructura y del negocio.

¿Qué es un data pipeline?



¿Qué es un data pipeline?

Consideraciones Clave

- ¿Cuál es el caso de uso de los datos que estoy ingiriendo?
- ¿Puedo reutilizar estos datos y evitar la ingesta de múltiples versiones del mismo conjunto de datos?
- ¿A dónde se dirigen los datos? ¿Cuál es el destino?
- ¿Con qué frecuencia deben actualizarse los datos desde la fuente?
- ¿Cuál es el volumen de datos esperado?

¿Qué es un data pipeline?

Consideraciones Clave

- ¿En qué formato están los datos?
 - ¿Pueden el almacenamiento y la transformación posteriores aceptar este formato?
- ¿Están los datos de origen en buen estado para su uso posterior inmediato?
 - ¿Son los datos de buena calidad?
 - ¿Qué posprocesamiento se requiere para entregarlos?
 - ¿Cuáles son los riesgos para la calidad de los datos (por ejemplo, podría el tráfico de bots a un sitio web contaminarlos)?
- ¿Requieren los datos procesamiento en tiempo real para su posterior ingesta si provienen de una fuente de streaming?

Componentes Principales: El Origen (Sources)

¿De dónde provienen los datos en un ecosistema empresarial?

Fuentes Operacionales y Estructuradas

- **Bases de Datos Relacionales (OLTP):**
 - PostgreSQL, MySQL, SQL Server.
 - Datos transaccionales y esquemas rígidos.
- **Archivos Consolidados (Batch):**
 - CSV, JSON, Parquet.
 - Cargas masivas.

Fuentes Conectadas y Semiestructuradas

- **APIs REST / Webhooks:**
 - Stripe, Salesforce, Google Ads.
 - Formatos JSON, sujetos a límites de consumo (*rate limits*).
- **Streaming y Eventos:**
 - Apache Kafka, Google Pub/Sub.
 - Datos continuos e infinitos.

Componentes principales

Transformación, Limpieza y Validación de Datos

El procesamiento (1/2)

Transforma el dato bruto (*raw data*) en un activo útil y confiable para el negocio. Aquí se ejecuta cómputo para:

- **Validación de Esquemas:**

- Verificación estructural del dato frente a un modelo (esquema) esperado.
- Desvío de registros corruptos a colas de descarte (*Dead-Letter Queues*).

- **Parseo y Conversión de Tipos:**

- Homogeneización de formatos (ej. castear texto a Timestamp o Float).
- Estandarización de codificaciones de caracteres (UTF-8).

Componentes principales

Transformación, Limpieza y Validación de Datos


El procesamiento (2/2)

- **Anonimización y Cumplimiento (Data Masking):**
 - Ofuscación o encriptación de datos sensibles de clientes (PII).
 - Garantía de seguridad antes de persistir el dato en el destino.
- **Limpieza y Enriquecimiento:**
 - Deduplicación, manejo de nulos e inyección de dimensiones de negocio.

Componentes principales

Destino

- Almacenamiento final
 - DataWarehouse
 - Datalake



Ingestión Batch

Definición

- Los datos se recopilan y procesan en grupos o **lotes** a intervalos de tiempo programados.
- En lugar de procesar la información a medida que llega, el pipeline espera hasta que se acumule un volumen específico de datos o hasta que se cumpla un horario (por ejemplo, cada hora, una vez al día o semanalmente) para iniciar la ingesta.

Ingestión Batch

Estrategias de extracción y carga masiva

Extracción Incremental (Diferencial):

- **Concepto:** Se extraen únicamente los datos que han cambiado (nuevos o modificados) desde la última ejecución exitosa del pipeline.
- **Ejemplo Real:** Logs de auditoría, clics de usuario o transacciones de venta diarias. No tiene sentido volver a leer todo el historial del año si solo requerimos el cierre del día de ayer.

Ingestión Batch

Estrategias de extracción y carga masiva

Extracción por Snapshot (Carga Completa):

- **Concepto:** Se extrae y sobrescribe la totalidad de la fuente de datos en cada ejecución, independientemente de si los registros sufrieron cambios o no.
- **Ejemplo Real:** Listado maestro de clientes, tabla de catálogo de productos o estados de cuentas. Son datos de dimensiones cuyo volumen es manejable y donde es crítico tener la última foto exacta del estado del negocio.

Ingestión Batch

Estrategias de extracción y carga masiva

Consideraciones Técnicas

- **Ingesta basada en Archivos:** Uso de almacenamiento intermedio (Object Storage como Google Cloud Storage o AWS S3) para staging masivo usando formatos óptimos (Parquet/Avro).
- **Manejo de Lotes (Batch Size):** Balancear el tamaño del lote. Lotes muy grandes saturan la memoria del pipeline; lotes muy pequeños incrementan los costos por exceso de conexiones de red y operaciones de I/O.


Ingestión de datos streaming

Definición

- Los datos se procesan de manera continua y a medida que llegan, con una latencia mínima.
- También conocida como ingesta en tiempo real (real-time).


Ingestión de datos streaming

Transformación básica



Ingestión de datos streaming

Transformación en Streaming



Ingestión de datos streaming

Consideraciones clave

- **Evolución del esquema**
- Datos que llegan tarde
- Orden y multiples entregas
- **Replay**
- Tiempo de retención de mensajes
- Tamaño de los mensajes
- **Manejo de errores y Dead-Letter Queues**
- Push y Pull del consumidor
- Ubicación

Desafíos comunes

Gestión de Fallas y Recuperación

- **Identificación temprana:** evitar que los datos corruptos lleguen al destino final.
- **Mecanismos de reintento.**
- **Recuperación de estado:** la capacidad de reanudar un pipeline desde el último punto de éxito.
- **Alertas y monitoreo.**

Desafíos comunes

Manejo de Datos Duplicados

- ¿Qué pasa si mi pipeline de cobros procesa un archivo dos veces?
- **Fuentes de duplicación:** ¿por qué se duplican los datos?
- Estrategias de deduplicación:
 - **En la fuente:** Intentar extraer solo los datos nuevos o modificados (cambios incrementales).
 - **Durante la transformación:** Utilizar identificadores únicos (claves primarias) para detectar y eliminar registros duplicados antes de cargarlos.
 - **En el destino:** Configurar el destino (por ejemplo, un Data Warehouse) para que rechace o actualice los registros duplicados en lugar de simplemente agregarlos.

Desafíos comunes

Escalabilidad


- Crecimiento del volumen de datos.
- Velocidad de procesamiento:
 - La necesidad de análisis en tiempo real o casi en tiempo real exige pipelines capaces de manejar grandes volúmenes a alta velocidad.
- Costos.
- Soluciones de escalabilidad:
 - Procesamiento distribuido
 - Arquitecturas en la nube

ETL tradicional

Definición

- Se basa en un sistema de transformación externo para extraer, transformar y limpiar los datos, preparándolos para un esquema de destino
- Los datos transformados se cargan posteriormente en un sistema de destino, como un datawarehouse, donde se pueden realizar análisis

ETL




Paso 1: Extract (Extracción)

Definición

- El objetivo es mover los datos desde su origen a un área de procesamiento.
- Estrategias:
 - Extracción Completa (Full Extraction)
 - Extracción Incremental (Incremental Extraction)
- Patrones de movimiento de datos:
 - Push
 - Pull
 - Poll

Paso 1: Extract (Extracción)

Patrones Push vs. Pull vs. Poll



Paso 1: Extract (Extracción)

Patrones Push vs. Pull vs. Poll

Push

- Baja latencia.
- Riesgo de saturar el destino si hay picos de tráfico.

Pull

- Control total del volumen.
- Ideal para snapshots e ingestas nocturnas.

Poll

- Monitoreo periódico.
- Puede generar sobrecarga innecesaria por consultas vacías.

Paso 2: Transform (Transformación)

Definición

- Los datos extraídos se limpian, enriquecen y preparan para su análisis.
- Es una de las fases más críticas, ya que convierte los datos brutos en información valiosa y coherente.
- Operaciones clave:
 - 1 Limpieza de Datos (Data Cleaning)
 - 2 Normalización y Estandarización
 - 3 Agregación y Enriquecimiento
 - 4 Filtrado y Selección

El Proceso de Transformación: Limpieza y Filtrado

Caso Real: Ingesta de Ventas Regionales

1. Dato Bruto / Sucio (Origen)

- **Problema:** Registros duplicados, valores nulos críticos y transacciones de prueba.

```
{'id': 101, 'ciudad': 'Santiago',  
'monto': 25000, 'status':  
'completed'}{'id': 101, 'ciudad':  
'Santiago', 'monto': 25000,  
'status': 'completed'}{'id':  
102, 'ciudad': 'Stgo', 'monto': 0,  
'status': 'TEST_DATA'}{'id': 103,  
'ciudad': 'Lima', 'monto': null,  
'status': 'completed'}
```

2. Dato Filtrado y Limpio (Destino)

- **Operaciones ejecutadas por el Pipeline:**
 - **Deduplicación:** Remoción por id.
 - **Filtrado:** Exclusión de TEST_DATA.
 - **Validación:** Descarte de montos null.

```
{'id': 101, 'ciudad': 'Santiago',  
'monto': 25000, 'status':  
'completed' }
```

El Proceso de Transformación: Normalización y Agregación

Caso Real: Homogeneización de Monedas y Consolidado Regional

1. Datos Desalineados (Formatos cruzados)

- **Problema:** Fechas en formatos distintos, monedas locales e inconsistencia en nombres.

```
{user": "ID_9", "fecha":  
"07/06/2026", "moneda": "CLP",  
"total": 95000}  
{user": "ID_12", "fecha":  
"2026-06-07", "moneda": "PEN",  
"total": 410}  
{user": "ID_4", "fecha":  
"07-Jun-2026", "moneda": ".ARS",  
"total": 92000}
```

2. Modelo Normalizado y Agregado

- **Operaciones ejecutadas por el Pipeline:**

- **Parseo:** Fechas estandarizadas a ISO.
- **Cálculo (ELT):** Conversión a USD basados en tabla de tipo de cambio.

```
+-----+-----+-----+  
| User_ID | Date_ISO | Total_USD |  
+-----+-----+-----+  
| ID_9 | 2026-06-07 | 100.00 | |  
ID_12 | 2026-06-07 | 110.50 | |  
| ID_4 | 2026-06-07 | 95.20 | |  
+-----+-----+-----+  
Total_Ventas_Regionales_USD => 305.70
```

Paso 3: Load (Carga)

Definición

- Los datos procesados se mueven al destino final.
- La elección de la estrategia de carga es fundamental para la eficiencia y la integridad de los datos.
- Estrategias de carga: , carga incremental (append), y upsert (insertar/actualizar).
 - Truncate: carga completa
 - Append: carga incremental
 - Upsert: insertar/actualizar

Paso 3: Load (Carga)

Eficiencia, Complejidad y Manejo de Estados

Dimensión	Truncate & Load	Append (Id-only)	Upsert (Merge)
Complejidad	Muy Baja: Sobre-escribe todo. No requiere lógica de negocio.	Baja: Inserta siempre al final. Riesgo de duplicados si se repite.	Alta: Requiere identificar claves primarias e historiales.
Rendimiento	Rápido para volúmenes pequeños; ineficiente en Big Data.	Máximo: Operación de escritura pura sin lecturas previas.	Medio/Bajo: Alta penalización por CPU/IO al comparar registros.
Manejo de Actualizaciones	No maneja; borra el pasado y guarda el presente exacto.	Ignora cambios. Genera múltiples versiones del mismo ID.	Ideal: Modifica si el registro existe; inserta si es nuevo.

Paso 3: Load (Carga)

Anatomía de un Upsert (Merge)

Algoritmo de Identidad

¿Existe la Primary Key en el destino?


- **SÍ:** Ejecuta UPDATE en los campos modificados.
- **NO:** Ejecuta INSERT de la nueva fila.

Paso 3: Load (Carga)

Destinos Comunes


- Bases de Datos Relacionales y No Relacionales
- Data Warehouses
- Data Lakes
- Servicios de Almacenamiento de Objetos

Patrones de diseño para ETL



- PSA: Persistent Staging Area

Patrones de diseño para ETL



- VSA: Volatile Staging Area


Patrones de diseño para ETL

Staging Volátil (VSA) vs. Persistente (PSA)

Dimensión	Volatile Staging Area (VSA)	Persistent Staging Area (PSA)
Concepto	Zona transitoria. Los datos se borran o purgan tras completarse la carga exitosa en el destino.	Zona de acumulación. Los datos históricos brutos se conservan indefinidamente.
Ciclo de Vida	Temporal: Ciclo de vida atado a la ejecución del pipeline (<i>Truncate</i> diario).	Permanente: Actúa como un registro histórico inmutable (<i>Append-only</i>).
Ventajas	Almacenamiento optimizado y económico. Menor mantenimiento de índices.	Permite auditorías completas y re-procesar datos históricos desde cero (<i>Reprocessing</i>).
Desventajas	Si el pipeline posterior falla o se corrompe el destino, se debe re-solicitar el dato al origen.	Alto costo de almacenamiento acumulativo. Requiere políticas estrictas de gobierno.

2024 AI and Data landscape

<https://mad.firstmark.com/>



Herramientas para ETL

Librerías Python

- Pandas
- SQLAlchemy
- PySpark
- Apache Beam

Herramientas para ETL

Servicios Nativos de la Nube

- AWS Glue
- Azure Data Factory
- Google Cloud Dataflow

Orquestadores

- Apache Airflow
- Luigi

ELT

ELT

- Se extraen datos sin procesar de un sistema fuente
- Se importan a un sistema de almacenamiento de datos con una transformación mínima
- Posteriormente, se limpian y transforman directamente en el sistema de almacenamiento

Precaución

- Ingerir datos sin un plan es una excelente opción para un data swamp

ELT

Extraction



Source A



Source B




Source C



Source D

Load



Datalake

Transform



Transform



Analytics

ETL vs ELT

ETL y ELT en la actualidad

- La línea entre ETL y ELT puede volverse algo difusa en los entornos cloud:
 - Almacenamiento de objetos como capa base
 - No está claro qué hay dentro y fuera de la base de datos
- Los términos ETL y ELT deberían aplicarse solo a nivel micro (dentro de los procesos de transformación individuales) en lugar de a nivel macro (para describir un patrón de transformación para toda una organización)

Herramientas comunes para ELT


dbt (data build tool)

- Es una herramienta de código abierto que se enfoca exclusivamente en la fase de transformación.
- dbt no extrae ni carga datos; asume que los datos ya han sido cargados (EL) en su destino (generalmente un data warehouse en la nube como Snowflake, BigQuery o Redshift).

Herramientas comunes para ELT

¿Cómo funciona un flujo de trabajo con dbt?

- **Extracción y Carga (EL):** Los datos brutos se extraen de las fuentes y se cargan directamente en el data warehouse utilizando una herramienta de ingesta como Fivetran o una solución personalizada.
- **Transformación con dbt (T):**
 - El ingeniero o analista define los modelos de datos en SQL.
 - dbt ejecuta esos modelos en el data warehouse, creando nuevas tablas o vistas que representan los datos limpios y transformados.
 - dbt gestiona las dependencias, ejecutando primero las transformaciones más simples y luego las más complejas.



FinOps: Eficiencia en Pipelines

Optimizando el valor del negocio a través de la arquitectura de datos.

En la nube, la ingeniería de datos no solo se mide por latencia, sino por costo-eficiencia. FinOps es la práctica de responsabilidad compartida entre finanzas e ingeniería.

- **Query Ops:** Uso de Partitioning y Clustering para reducir el escaneo de datos (Scan costs) en BigQuery/Snowflake.
- **Right-sizing:** Ajuste dinámico de clusters y políticas de auto-suspend para evitar costos de cómputo inactivo.
- **Lifecycle:** Gestión de niveles de almacenamiento (Hot, Cold, Archive) según la frecuencia de acceso al dato.
- **Attribution:** Etiquetado (Tagging) granular para mapear el costo del pipeline directamente a la unidad de negocio.

Contratos de Datos (Data Contracts)

- Un contrato de datos es un acuerdo programático entre productores y consumidores para evitar la degradación de pipelines por cambios imprevistos en el origen.
- **Reactivo:** El pipeline falla, el negocio se detiene y el ingeniero repara el daño.
- **Proactivo:** El cambio se valida antes de subir a producción, protegiendo al consumidor.

Contratos de Datos (Data Contracts)

Anatomía de un Contrato

- **Esquema Técnico:** Define tipos de datos (Int, String), nulidad, llaves primarias y restricciones de formato estrictas.
- **Semántica del Negocio:** Metadatos que explican el significado real del dato (ej. "Monto neto antes de IVA en pesos chilenos").
- **SLA y Calidad:** Acuerdos de frescura (frecuencia), integridad y rangos permitidos (ej. "Monto debe ser mayor a cero").
- **Seguridad / PII:** Identificación explícita de campos sensibles para políticas automáticas de encriptación y anonimización.

Contratos de Datos (Data Contracts)

Datos como Producto

- El contrato de datos integra el pipeline de ingeniería de software con el de datos:
- **Puerta de enlace CI/CD:** Si un despliegue de software rompe el contrato, el test falla y bloquea el deploy.
- **Responsabilidad Compartida:** El productor del dato se vuelve dueño de su calidad técnica.
- **Estabilidad Garantizada:** El consumidor (Data Science/BI) recibe datos confiables y estables.

Clase 1: Data Pipelines y ETL

Módulo 7: Data Pipelines y plataformas de visualización

Claudio Torres Fonseca

mail: `claudio.torresf@usm.cl`

Universidad de Santiago de Chile

Diplomado en Data Engineer
2026