



UNIVERSIDAD
DE SANTIAGO
DE CHILE

Diplomado en *Data Engineer*

Módulo 8: Fundamentos de Visualización de Datos

José Luis Martí Lara

Ingeniero Civil Informático (UTFSM) - Magíster en Ingeniería Informática (UTFSM)

Máster en Diseño de Información y Visualización de Datos (UPF)

Docente y Jefe de Carrera del Departamento de Informática - UTFSM

joseluis.martilara@gmail.com



UNIVERSIDAD
DE SANTIAGO
DE CHILE

Diplomado en *Data Engineer*

Tema 5:

Visualización de Datos

y Ciencia de Datos


Ciencia de Datos

- La ciencia de datos es el estudio científico de los datos para obtener conocimiento.
- Combina varias disciplinas para extraer conclusiones de conjuntos de datos masivos con el fin de tomar decisiones y realizar predicciones de manera informada.

<https://azure.microsoft.com/es-es/resources/cloud-computing-dictionary/what-is-data-Engineer>



APRENDIZAJE AUTOMÁTICO CLÁSICO






Asociación



https://gerardnico.com/wiki/data_mining/association



Asociación

- Tarea descriptiva de aprendizaje no supervisado
- Objetivo: descubrir *relaciones y patrones* entre atributos

- Estructura:

antecedente $\Rightarrow$ *consecuente*

- Ejemplos:

(compra leche) $\Rightarrow$ (compra plátano)

(compra pan) y (compra jamón) $\Rightarrow$ (compra queso)

Asociación

- Tipos de valores manejados por la regla:
 - Regla booleana: las asociaciones indican la ausencia o presencia de los elementos, tal como:

computador → impresora

- Regla cuantitativa: las asociaciones describen relaciones entre atributos cuantitativos, por ejemplo:

(30 < edad < 39) and (ingreso > 500.000) →

TV con pantalla plana

Asociación

- Dimensiones de los datos:
 - Regla unidimensional: los atributos hacen referencia a una única dimensión, por ejemplo:

computador → impresora

- Regla multidimensional: se hace referencia a dos o más dimensiones, tal como:

(30 < edad < 39) and (ingreso > 500.000) →

TV con pantalla plana

Asociación

- Reglas en función del tiempo
 - Regla instantánea: indica relaciones inmediatas, contemporáneas:

computador → impresora

- Regla secuencial: establece un orden temporal:

computador → impresora en próxima compra

computador → impresora antes de tres meses

Asociación


- Ocurrencia en las Reglas
 - Regla positiva: indica la ocurrencia de los ítemes:
computador → impresora
 - Regla negativa: indica la no presencia de, al menos, uno los ítemes de la regla:

computador → not impresora



- Uso de niveles de abstracción:

Asociación



Asociación

- Métricas (1)

- Soporte: corresponde a la representatividad de la regla. Es el número de casos o porcentaje en los que el antecedente y consecuente se hacen verdadero, siendo n el número de datos en estudio.

$$\text{soporte}(A \rightarrow C) = (r_a + r_c) \text{ o } (r_a + r_c)/n$$

- Confianza: corresponde a la certeza de la regla. Es el número de casos que, habiendo cumplido con el antecedente de la regla, también se cumple el consecuente de la misma.

$$\text{confianza}(A \rightarrow C) = (r_c / r_a)$$

Asociación

- Métricas (2)
 - *Lift* (elevación): mide la fuerza de la asociación entre los ítems. Un *lift* > 1 indica que ambos ocurren juntos con mayor frecuencia que la esperada si fueran independientes.

$$\text{lift}(A \rightarrow B) = \text{confianza}(A \rightarrow B) / \text{soporte}(B)$$

Asociación

- Algoritmos: en general, consideran dos etapas:
 - Fase 1 – Búsqueda de *itemsets* frecuentes: se identifican los conjuntos de ítems cuyo soporte es mayor o igual a un soporte mínimo. Solo se determinan los *itemsets* que aparecen con suficiente frecuencia, sin distinguir aún antecedente y consecuente.
 - Fase 2 – Generación de reglas de asociación: A partir de cada *itemset* frecuente se generan todas las posibles particiones binarias y disjuntas entre antecedente y consecuente. Para cada regla candidata se calcula su confianza, conservándose sólo aquellas cuya confianza es mayor o igual a una confianza mínima establecida.

Asociación

- **Algoritmo: Apriori**
 - Su nombre es debido a que se basa en conocimientos previos sobre la frecuencia de los itemsets, al usar los k -itemsets para explorar los del siguiente nivel o paso ($k+1$).
 - Condición apriori: todos los subconjuntos de un itemset frecuente deben ser frecuentes.
 - Propiedad anti-monótona: si un conjunto no supera una prueba, los supra-conjuntos derivados tampoco la superarán.
- Ejemplo de cómo trabaja ...

- Algoritmo: Apriori (1)

Fase 1: búsqueda de itemsets frecuentes

Datos de ejemplo:

Cliente	(Compra?) Producto				
	1	2	3	4	5
A	X		X		
B		X	X		X
C	X	X	X		X
D				X	X
E	X	X			X

Considerar un soporte mínimo del 0.4.



Asociación

- Algoritmo: Apriori (2)

Cliente	(Compra?) Producto				
	1	2	3	4	5
A	X		X		
B		X	X		X
C	X	X	X		X
D				X	X
E	X	X			X

$$S_1 = \{ \{P1\}, \{P2\}, \{P3\}, \{P4\}, \{P5\}, \}$$

$$\rightarrow S_1' = \{ \{P1\}:3, \{P2\}:3, \{P3\}:3, \{P5\}:4 \}$$

$$S_2 = \{ \{P1,P2\}, \{P1,P3\}, \{P1,P5\}, \{P2,P3\}, \{P2,P5\}, \{P3,P5\} \}$$

$$\rightarrow S_2' = \{ \{P1,P2\}:2, \{P1,P3\}:2, \{P1,P5\}:2, \\ \{P2,P3\}:2, \{P2,P5\}:3, \{P3,P5\}:2 \}$$

$$S_3 = \{ \{P1,P2,P3\}, \{P1,P2,P5\}, \{P1,P3,P5\}, \{P2,P3,P5\} \}$$

$$\rightarrow S_3' = \{ \{P1,P2,P5\}:2, \{P2,P3,P5\}:2 \}$$

$$S_4 = \{ \{P1,P2,P3,P5\} \}$$

$$\rightarrow S_4' = \{ \}$$

$$S_{\text{final}} = S_2' \cup S_3' = \{ \{P1,P2\}, \{P1,P3\}, \{P1,P5\}, \{P2,P3\}, \{P2,P5\}, \\ \{P3,P5\}, \{P1,P2,P5\}, \{P2,P3,P5\} \}$$



Asociación

- Algoritmo: Apriori (3)

Fase 2: esclarecimiento de dependencias

$\{P1\} \rightarrow \{P2\} : 0.67$

$\{P1\} \rightarrow \{P3\} : 0.67$

$\{P1\} \rightarrow \{P5\} : 0.67$

$\{P2\} \rightarrow \{P3\} : 0.67$

$\{P2\} \rightarrow \{P5\} : 1$

$\{P3\} \rightarrow \{P5\} : 0.67$

$\{P2\} \rightarrow \{P1\} : 0.67$

$\{P3\} \rightarrow \{P1\} : 0.67$

$\{P5\} \rightarrow \{P1\} : 0.5$

$\{P3\} \rightarrow \{P2\} : 0.67$

$\{P5\} \rightarrow \{P2\} : 0.75$

$\{P5\} \rightarrow \{P3\} : 0.5$

$\{P1, P2\} \rightarrow \{P5\} : 1$

$\{P1, P5\} \rightarrow \{P2\} : 1$

$\{P2, P5\} \rightarrow \{P1\} : 0.67$

$\{P5\} \rightarrow \{P1, P2\} : 0.5$

$\{P2\} \rightarrow \{P1, P5\} : 1$

$\{P1\} \rightarrow \{P2, P5\} : 0.67$

$\{P2, P3\} \rightarrow \{P5\} : 1$

$\{P2, P5\} \rightarrow \{P3\} : 0.67$

$\{P3, P5\} \rightarrow \{P2\} : 1$

$\{P5\} \rightarrow \{P2, P3\} : 0.5$

$\{P3\} \rightarrow \{P2, P5\} : 0.67$

$\{P2\} \rightarrow \{P3, P5\} : 0.67$

Cliente	(Compra?) Producto				
	1	2	3	4	5
A	X		X		
B		X	X		X
C	X	X	X		X
D				X	X
E	X	X			X



Asociación

- Algoritmo: Apriori (4)

Fase 2: esclarecimiento de dependencias

Confianza mínima: 0.6

$\{P2\} \rightarrow \{P5\} : 1$
 $\{P2, P3\} \rightarrow \{P5\} : 1$
 ...
 $\{P5\} \rightarrow \{P2\} : 0.75$
 $\{P1\} \rightarrow \{P2\} : 0.67$
 $\{P2\} \rightarrow \{P1\} : 0.67$
 $\{P1\} \rightarrow \{P3\} : 0.67$
 $\{P3\} \rightarrow \{P1\} : 0.67$
 $\{P1\} \rightarrow \{P5\} : 0.67$
 ...
 $\{P3\} \rightarrow \{P5\} : 0.67$

Confianza mínima: 0.75

$\{P2\} \rightarrow \{P5\} : 1$
 $\{P2, P3\} \rightarrow \{P5\} : 1$
 ...
 $\{P5\} \rightarrow \{P2\} : 0.75$

Cliente	(Compra?) Producto				
	1	2	3	4	5
A	X		X		
B		X	X		X
C	X	X	X		X
D				X	X
E	X	X			X

Asociación

- Algoritmo: Apriori - extensiones
 - Usar una muestra de los datos
 - Filtro (selección) de atributos
 - Paralelismo
 - Aplicación a atributos numéricos → discretización; segmentación y asignar un valor discreto a cada grupo.
- Ejercicios ...



• Ejemplo con Visualización de Datos (1)

Asociación

- Archivo: verduras.csv
- 500 compras de productos: Palta, Rúcula, Choclo, Lechuga, Repollo, Betarraga, Berros, Arvejas, Champiñones y Zanahoria
- Soporte: 20% - Confianza: 65%


```
> reglasordenadas <- head(sort(reglas, by = "confidence"), 10)
> inspect(reglasordenadas)
```

	lhs	rhs	support	confidence	coverage	lift	count
[1]	{Arvejas=0, Zanahoria=1}	=> {Champiniones=1}	0.214	0.9816514	0.218	1.305387	107
[2]	{Berros=1, Arvejas=0}	=> {Champiniones=1}	0.224	0.9739130	0.230	1.295097	112
[3]	{Choclo=0, Berros=0}	=> {Arvejas=1}	0.200	0.8849558	0.226	1.267845	100
[4]	{Arvejas=1, Zanahoria=0}	=> {Champiniones=1}	0.220	0.8148148	0.270	1.083530	110
[5]	{Choclo=0, Lechuga=1}	=> {Champiniones=1}	0.238	0.8095238	0.294	1.076494	119
[6]	{Choclo=1, Lechuga=0}	=> {Champiniones=1}	0.238	0.8095238	0.294	1.076494	119
[7]	{Lechuga=1, Betarraga=1}	=> {Arvejas=1}	0.212	0.8091603	0.262	1.159255	106
[8]	{Repollo=1, Betarraga=0}	=> {Champiniones=1}	0.224	0.8000000	0.280	1.063830	112
[9]	{Rucula=0, Betarraga=0}	=> {Champiniones=1}	0.200	0.8000000	0.250	1.063830	100
[10]	{Rucula=1, Choclo=0}	=> {Arvejas=1}	0.220	0.7971014	0.276	1.141979	110



- Ejemplo con Visualización de Datos (2)


Asociación





- Ejemplo con Visualización de Datos (3)


Asociación





- Ejemplo con Visualización de Datos (4)

Asociación






- Ejemplo con Visualización de Datos (5)

Asociación

```
> reglasconfianza <- head(sort(reglas, by = "confidence"), 5)
> inspect(reglasconfianza)
```

	lhs	rhs	support	confidence	coverage	lift	count
[1]	{Arvejas=0, Zanahoria=1}	=> {championiones=1}	0.214	0.9816514	0.218	1.305387	107
[2]	{Berros=1, Arvejas=0}	=> {championiones=1}	0.224	0.9739130	0.230	1.295097	112
[3]	{choclo=0, Berros=0}	=> {Arvejas=1}	0.200	0.8849558	0.226	1.267845	100
[4]	{Arvejas=1, Zanahoria=0}	=> {championiones=1}	0.220	0.8148148	0.270	1.083530	110
[5]	{choclo=0, Lechuga=1}	=> {championiones=1}	0.238	0.8095238	0.294	1.076494	119





APRENDIZAJE AUTOMÁTICO CLÁSICO




Clustering

- Corresponde a una técnica de **aprendizaje no supervisado**, ya que no utiliza clases predefinidas ni ejemplos previamente etiquetados
- En lugar de aprender a partir de ejemplos, descubre de forma automática agrupamientos o patrones presentes en los datos.

Clustering

- Encontrar agrupamientos de tal forma que los objetos de un grupo sean similares entre sí, y diferentes de los objetos de otros grupos.



El objetivo es reunir los datos en grupos de acuerdo a la “relación de cercanía (distancia)” que se encuentre entre ellos.

Clustering

- El elemento clave es la elección de la distancia o medida de similitud entre objetos.

Distancia de Minkowski

$$d_r(x, y) = \left(\sum_{j=1}^J |x_j - y_j|^r \right)^{\frac{1}{r}}, \quad r \geq 1$$

- > Distancia de Manhattan ($r=1$) / city block / taxicab

$$d_1(x, y) = \sum_{j=1}^J |x_j - y_j|$$



- > Distancia euclídeana ($r=2$):

$$d_2(x, y) = \sqrt{\sum_{j=1}^J (x_j - y_j)^2}$$


- > Distancia de Chebyshev ($r \rightarrow \infty$) / dominio / chessboard

$$d_{\infty}(x, y) = \max_{j=1..J} |x_j - y_j|$$

Distancia de Minkowski



Manhattan




Euclidean

- > Distancia de Manhattan = 12
- > Distancia Euclídea ≈ 8.5
- > Distancia de Chebyshev = 6

Clustering

- Tipos de algoritmos


1) Métodos de **Particionamiento**: dada una base de datos con n objetos, un método de este tipo construye k particiones, donde cada una de éstas representa un grupo, siendo $k \leq n$. Ejs.: K-Means, K-Medoids (PAM).




Clustering

- Tipos de algoritmos


2) Métodos **Jerárquicos**: crea una descomposición jerárquica del conjunto de datos dado. Ejs.: BIRCH, CURE.




Tradicional



No tradicional





DENDROGRAMA



Clustering

- Tipos de algoritmos


3) Métodos **basados en Densidad**: la idea general es continuar creciendo el grupo dado tanto como la densidad (número de objetos o puntos de datos) en la vecindad exceda algún umbral. Ejs.: DBSCAN, OPTICS.



Clustering

- Tipos de algoritmos

4) Métodos **basados en la Grilla**: cuantiza el espacio de objetos en un número finito de celdas que conforman una estructura de grilla. Entonces realizar todas las operaciones de agrupamiento en esta última. Ejs.: STING, CLIQUE, Wave-Cluster.




Clustering

- Tipos de algoritmos

5) Métodos basados en **Modelo**: hipotetiza un modelo por cada uno de los grupos, y encuentra el mejor ajuste de los datos a ese modelo; puede localizar los grupos al construir una función de densidad que refleje la distribución espacial de los puntos de datos.

- Enfoque Estadístico: algoritmos COBWEB, CLASSIT.
- Enfoque de Red Neuronal: SOM o Mapas AutoOrganizados (Redes de Kohonen).




Clustering

- Tipos de algoritmos – métodos de particionamiento: algoritmo **K-means** (1).
 - Divide aleatoriamente los ejemplos en k conjuntos y calcular la media (el punto medio) cada conjunto.
 - Reasigna cada ejemplo al conjunto con el punto medio más cercano.
 - Calcula los puntos medios de los k conjuntos.
 - Repetir los pasos 2 y 3 hasta que los conjuntos no varíen.



Clustering

- Tipos de algoritmos – métodos de particionamiento:
algoritmo **K-means** (2).




	A1	A2	A3	A4	A5	A6	A7	A8
A1	0	$\sqrt{25}$	$\sqrt{36}$	$\sqrt{13}$	$\sqrt{50}$	$\sqrt{52}$	$\sqrt{65}$	$\sqrt{5}$
A2		0	$\sqrt{37}$	$\sqrt{18}$	$\sqrt{25}$	$\sqrt{17}$	$\sqrt{10}$	$\sqrt{20}$
A3			0	$\sqrt{25}$	$\sqrt{2}$	$\sqrt{2}$	$\sqrt{53}$	$\sqrt{41}$
A4				0	$\sqrt{13}$	$\sqrt{17}$	$\sqrt{52}$	$\sqrt{2}$
A5					0	$\sqrt{2}$	$\sqrt{45}$	$\sqrt{25}$
A6						0	$\sqrt{29}$	$\sqrt{29}$
A7							0	$\sqrt{58}$
A8								0


Distancias Euclidianas

Clustering


- Tipos de algoritmos – métodos de particionamiento:
algoritmo **K-means** (3).




Iteración 1



Iteración 2



Iteración 3




Iteración 4


Clustering

- Tipos de algoritmos – métodos de particionamiento:
algoritmo **K-means** (4): posibles problemas.


- Si se sabe que hay n clases, hacer $k=n$ puede resultar en que, algunas veces, algún grupo use dos centros y dos grupos separados tengan que compartir centro.



- Si k se elige muy grande, la generalización es pobre y las agrupaciones futuras serán malas.



- Determinar el k ideal es difícil.



Clustering

- Tipos de algoritmos – métodos de particionamiento:
algoritmo **K-means** (5): variantes
 - **K-modes**: para datos categóricos, al reemplazar los promedios de los grupos por las modas.
 - **K-medoids**: basado en puntos representativos...

Clustering

- Tipos de algoritmos – métodos de particionamiento:
algoritmo **K-means** (5): vs. **K-medoids**.




Figure 8.2: Clustering of a set of points based on the **k-means** method




Figure 8.4: Clustering of a set of points based on the **k-medoids** method

Clustering


- Tipos de algoritmos – métodos de jerárquicos: posibilidades.
 - **Aglomerativo** (esquema *bottom-up*): empieza con cada objeto formando un grupo separado; sucesivamente mezcla los (grupos de) objetos cercanos entre sí, hasta que se cumpla cierta condición dada.
 - **Divisible** (esquema *top-down*): empieza con todos los objetos en el mismo grupo; en cada iteración sucesiva, un grupo es dividido en otros más pequeños, hasta que eventualmente se cumpla cierta condición dada.

Clustering

- Tipos de algoritmos – métodos de jerárquicos: posibilidades.

Enfoque Aglomerativo (*bottom-up*)

Algoritmo: AGNES (**AG**glomerative **NE**sting)




Enfoque Divisivo (*top-down*)

Algoritmo: DIANA (**DI**visive **ANA**lysis)



Clustering


- Tipos de algoritmos – métodos de jerárquicos: dendrograma.




La "similitud" entre dos objetos viene dada por la "altura" del nodo común más cercano.



Clustering



El dendrograma puede ayudar a determinar el número de grupos...





Clustering


Para medir la
distancia entre
grupos...

- MIN
Enlace simple

$$\min_{x_i \in S_i, x_j \in S_j} d(x_i, x_j)$$

- MAX
enlace completo
(diámetro)

$$\max_{x_i \in S_i, x_j \in S_j} d(x_i, x_j)$$






Clustering

Para medir la
distancia entre
grupos...

- PROMEDIO
Enlace promediado

$$\frac{1}{|S_i||S_j|} \sum_{x_i \in S_i} \sum_{x_j \in S_j} d(x_i, x_j)$$


- basado en CENTROIDES
Ej.: **BIRCH**.






Clustering

- Dendrograma: ejemplo gráfico para cuatro grupos



Enlace único




Enlace completo




Clustering

- Dendrograma: ejemplo gráfico para datos aleatorios




Enlace único



Enlace completo



APRENDIZAJE AUTOMÁTICO CLÁSICO



Clasificación

- Tarea predictiva, supervisada
- Es el trabajo de encontrar un modelo que describa y distinga clases de datos o conceptos, con el propósito de conocer la clase de otros objetos que aún no la tienen definida.
- En general:
 - Clasificación: predice el valor de un atributo cualitativo (categórico).
 - Regresión: construye funciones que toman valores numéricos (continuos).

Clasificación

- Construcción en dos fases:
 - Se divide el conjunto de datos disponible en un **conjunto de entrenamiento** para construir el modelo y un **conjunto de prueba** para evaluarlo.
 - Se construye el modelo usando el conjunto de entrenamiento, y se valida con el de prueba, obteniéndose un porcentaje de clasificación asociado al número de aciertos obtenidos.
 - Si dicho porcentaje es aceptable, el modelo es considerado como útil para clasificar nuevos casos.




Clasificación

Tid	Attrib1	Attrib2	Attrib3	Class
1	Yes	Large	125K	No
2	No	Medium	100K	No
3	No	Small	70K	No
4	Yes	Medium	120K	No
5	No	Large	95K	Yes
6	No	Medium	60K	No
7	Yes	Large	220K	No
8	No	Small	85K	Yes
9	No	Medium	75K	No
10	No	Small	90K	Yes

Conjunto de
entrenamiento


Tid	Attrib1	Attrib2	Attrib3	Class
11	No	Small	55K	?
12	Yes	Medium	80K	?
13	Yes	Large	110K	?
14	No	Small	95K	?
15	No	Large	67K	?

Conjunto de prueba



Clasificación

- Alternativas para trabajar con Conjuntos de Entrenamiento y de Prueba:
 - Usar el mismo conjunto de entrenamiento como de prueba.
 - Diseñar un conjunto de prueba específico.
 - Validación cruzada.
 - División del conjunto de datos en dos: uno de entrenamiento y otro de prueba.




Clasificación

- Validación Cruzada
 - Se divide el conjunto de datos, aleatoriamente, en k subconjuntos de intersección vacía (más o menos del mismo tamaño); por lo general, $k=10$.
 - En la iteración i , se usa el subconjunto i como conjunto de prueba y los $k-1$ restantes como conjunto de entrenamiento.
 - Como medida de evaluación del método de clasificación se toma el promedio aritmético de las k iteraciones realizadas.



- Validación Cruzada

Clasificación




Validación Cruzada ($k = 4$)




Clasificación

- Estimación de la precisión del clasificador:
- Cuanto mayor sea su complejidad, los modelos de clasificación tienden a ajustarse más al conjunto de entrenamiento utilizado en su construcción.



Sobreaprendizaje debido
a la presencia de ruido en los datos



Sobreaprendizaje debido
a la escasez de muestras

Clasificación

- Estimación de la precisión del clasificador: métricas
 - a) Matriz de confusión

		Predicción	
		C _P	C _N
Clase real	C _P	TP: True positive	FN: False negative
	C _N	FP: False positive	TN: True negative

La exactitud del clasificador viene dada por la expresión:

$$\text{accuracy} = \frac{(TP+TN)}{(TP+TN+FP+FN)}$$



- Estimación de la precisión del clasificador: métricas

Clasificación

		Predicción	
		C _p	C _N
Real	C _p	TP	FN
	C _N	FP	TN
Accuracy			

		Predicción	
		C _p	C _N
Real	C _p	TP	FN
	C _N	FP	TN
Recall			

		Predicción	
		C _p	C _N
Real	C _p	TP	FN
	C _N	FP	TN
Precision			

		Predicción	
		C _p	C _N
Real	C _p	TP	FN
	C _N	FP	TN
F-measure			

$$\text{precision} = \frac{TP}{(TP+FP)}$$

$$\text{recall} = \text{sensitivity} = \frac{TP}{(TP+FN)}$$

$$\text{specificity} = \frac{TN}{(TN+FP)}$$


$$\text{F-measure} = \frac{2 * \text{precision} * \text{recall}}{\text{precision} + \text{recall}} = \frac{2 TP}{2TP + FP + FN}$$



Clasificación

- Estimación de la precisión del clasificador: métricas
b) Curvas ROC

Tasa de Verdaderos
Positivos
 $TP/(TP+FN)$



Tasa de Falsos Positivos
 $FP/(FP+TN)$

Clasificación


- Tipos de Algoritmos:
 - Métodos básicos: ZeroR, OneR
 - Árboles de clasificación.
 - Inducción de reglas de clasificación.
 - Métodos bayesianos.
 - Métodos basados en casos y vecindad.
 - Máquinas de Soporte Vectorial.
 - Redes neuronales artificiales.



Clasificación

Tiempo	Temperatura	Humedad	Viento?	Juega Tenis
Lluvioso	Alta	Alta	Falso	NO
Lluvioso	Alta	Alta	Verdadero	NO
Nublado	Alta	Alta	Falso	SÍ
Soleado	Media	Alta	Falso	SÍ
Soleado	Baja	Normal	Falso	SÍ
Soleado	Baja	Normal	Verdadero	NO
Nublado	Baja	Normal	Verdadero	SÍ
Lluvioso	Media	Alta	Falso	NO
Lluvioso	Baja	Normal	Falso	SÍ
Soleado	Media	Normal	Falso	SÍ
Lluvioso	Media	Normal	Verdadero	SÍ
Nublado	Media	Alta	Verdadero	SÍ
Nublado	Alta	Normal	Falso	SÍ
Soleado	Media	Alta	Verdadero	NO

Ejemplo de
árbol de
clasificación



FIN