

**UNIVERSIDAD DE SANTIAGO
FACULTAD DE ADMINISTRACIÓN Y ECONOMÍA
DIPLOMADO EN DATA ENGINEER**

Módulo 8: Fundamentos de Visualización de Datos
Trabajo Final: Informe Técnico sobre una Plataforma de Datos

Profesor: José Luis Martí Lara

Objetivo:

Elaborar un informe técnico que diagnostique el comportamiento de una plataforma de datos utilizando diferentes herramientas de análisis y visualización de datos.

Modalidad de Trabajo:

Grupos de dos personas (trabajos desarrollados de forma individual serán evaluados con nota 1.0)

Enunciado:

La empresa JLMLSys Solutions opera una plataforma de datos que integra información de múltiples sistemas, en la cual se han detectado problemas de rendimiento, calidad de datos e incidentes operacionales.

Se pide:

A partir del dataset asignado, según el número de grupo:

Flourish

1. Construir una historia que describa el comportamiento de la plataforma, según el criterio también asignado. Esta historia debe estar compuesta por:
 - a) Una visualización estática, la cual no puede ser de ninguno de los siguientes tipos: "line chart", "bar chart", "columna (chart)", "scatter" o similares
 - b) Una visualización dinámica, de cualquier tipo
 - c) Un grafo o un mapa, de cualquier tipo

Tableau

2. Construir un *dashboard* con al menos dos visualizaciones que complementen la información presente en la historia del punto anterior. No hay restricción del tipo de visualización a incluir en dicho *dashboard*.

Orange Canvas

3. Obtener un resultado que complemente las respuestas anteriores, considerando uno de los siguientes resultados:
 - a) Un conjunto de reglas de asociación, acompañado del soporte y confianza mínimos usados para obtenerlo.
 - b) Un conjunto de clusters, acompañado de la configuración usada para generarlo junto con alguna métrica de rendimiento.
 - c) Un clasificador, preferentemente un árbol de clasificación, junto con la configuración usada para llegar a éste, y las métricas de rendimiento asociadas (matriz de confusión, curva ROC)

Informe técnico

4. Integrar todo lo anterior en un archivo *pdf* de no más de 8 páginas, que contenga los cinco resultados pedidos, cada uno con la visualización de datos y su correspondiente explicación. Las visualizaciones se pueden insertar como archivos jpeg, sino como screenshots (de buena calidad), y seguir un hilo conductor claro de la descripción del caso asignado. Adicionalmente, poner como pie de alguna página, la URL de la historia construida en Flourish (recordar que ésta no puede “terminar” en la palabra “edit”, porque así no será posible acceder a su contenido).
5. Finalizar el informe con una conclusión técnica del caso de estudio y los resultados obtenidos.

Consideraciones:

- a) En los anexos (ver más adelante) están el diccionario de datos del dataset, y por cada grupo de trabajo, el escenario y tema a estudiar asignados.
- b) Se espera que con las visualizaciones de datos a construir se realice un análisis exploratorio y descriptivo, enfocado en el tema a estudiar.
- c) La entrega consiste en un único informe en formato pdf, a subir al aula virtual del curso, a más tardar el domingo 12 de julio, 23:59 horas.
- d) Se evaluará la coherencia de las decisiones tomadas y profundidad técnica (ver anexo).

**JLML/jlml.
030726.**

Anexo 1: Diccionario de Datos

	Variable	Tipo	Descripción
A	Escenario	---	---
B	Pipeline_ID	Categoría	Identificador del pipeline
C	Fecha	Fecha	Fecha de ejecución
D	Hora_Inicio	Hora	Inicio del proceso
E	Hora_Fin	Hora	Fin del proceso
F	Tipo_Pipeline	Categoría	Batch/Streaming
G	Sistema_Origen	Categoría	ERP/CRM/POS/IoT/Web
H	Prioridad	Categoría	Baja/Media/Alta
I	Reintentos	Númerica	Número de reintentos
J	Tiempo_Ejecución	Númerica	Segundos
K	Registros_Procesados	Númerica	Cantidad de registros
L	Throughput	Númerica	Registros/segundo
M	CPU	Númerica	Uso CPU (%)
N	RAM	Númerica	Uso RAM (%)
O	Disco	Númerica	Uso disco (%)
P	Latencia	Númerica	Latencia (ms)
Q	Nulos	Númerica	Porcentaje de nulos
R	Duplicados	Númerica	Porcentaje de duplicados
S	Registros_Rechazados	Númerica	Cantidad
T	Reglas_Calidad	Númerica	Reglas incumplidas
U	Severidad	Categoría	Baja/Media/Alta
V	Región	Categoría	Zona geográfica
W	Latitud	Númerica	Latitud
X	Longitud	Númerica	Longitud
Y	Estado	Categoría	OK/FAIL (objetivo)

Anexo 2: Asignación de Escenarios

Escenario asignado	Tema a estudiar	Grupo
1	Sobrecarga de CPU (identificar cuellos de botella por procesamiento)	José Acevedo Cavieres Pablo Bermúdez Cisternas
2	Saturación de memoria (analizar uso excesivo de RAM)	Nicolás Aguirre Domínguez Carlos Salinas Morales
3	Latencia elevada (detectar problemas de comunicación)	Leandro Alegría González Marco Pino Bustos
4	Exceso de registros (analizar impacto del volumen de datos)	Verónica Andrade Valeria Michael Moscoso Ramírez
5	Mala calidad de los datos (investigar reglas de calidad incumplidas)	Alí Ayala Gómez Germán Rivera Pino
6	Datos Duplicados (identificar causas y efectos)	Pedro Barraza Rivera Valeria Luna Meza
7	Valores Nulos (analizar impacto sobre el procesamiento)	Alexandra Brain Román Karla Soto Rubio
8	Reintentos excesivos (detectar procesos inestables)	Sebastián Carvallo Toro Ricardo Ortiz Morales
9	Problemas IoT (identificar patrones de sensores)	Ariel Castro Mieres Jorge Troncoso Alarcón
10	Problemas CRM (analizar comportamiento de una fuente)	Andrés Cifuentes Vargis Eduardo López Iturra
11	Problemas ERP (analizar comportamiento de una fuente)	Alexander Cortés Fredes Alex Pino Moya
12	Incidentes críticos (relación entre rendimiento e incidentes)	Pablo Gálvez Labrín Sergio Véliz Marín
13	Pipelines <i>batch</i> (comparar con <i>streaming</i>)	Amparo Herrera Madariaga Juan Pino Valdés
14	Pipelines <i>streaming</i> (comparar con <i>batch</i>)	Damián Huilipán Caniupán Ignacio Muñoz Alegría
15	Región norte (análisis por zona)	Loana León Ferreira Nataly Rojas Albornoz
16	Región centro (análisis por zona)	Sergio Martínez Gallegos Brayan Parra Ruz
17	Región sur (análisis por zona)	Héctor Muñoz Bonilla Priscilla Readí Ananías
18	Dependencias complejas (identificar procesos críticos)	Abraham Muñoz Sáez Daniela Sánchez Nizza
19	Plataforma web (analizar cargas variables)	Benjamín Parraguez Contreras Roberto Vargas Jabre
20	<i>Throughput</i> bajo (explicar pérdida de rendimiento)	Iván Pérez Alarcón Jorge Vera Alarcón