

Tarea 1

Módulo 9 - Computación en la nube y cloud serveless

Claudio Torres Fonseca

mail: claudio.torresf@usm.cl

Diplomado en Data Engineer

2026

1. Contexto del Negocio

La cadena minorista internacional *LatamBuy* está experimentando problemas críticos de escalabilidad y análisis de información en su sucursal regional. Actualmente, la aplicación web que registra las ventas de los clientes opera sobre una base de datos local desactualizada, lo que genera caídas continuas en el servicio y pérdida de transacciones operativas.

Además, el equipo de Business Intelligence (BI) no puede generar reportes de rendimiento porque los datos históricos de compras se encuentran dispersos en archivos planos dentro de un repositorio de almacenamiento.

Como Ingeniero(a) de Datos Senior, se le ha encomendado resolver este dolor de punta a punta a través de dos grandes hitos tecnológicos:

1. **Fase Transaccional (OLTP):** Migrar y desplegar la base de datos de la aplicación a una arquitectura en la nube con alta disponibilidad y alta tolerancia a fallos.
2. **Fase Analítica (OLAP):** Construir un pipeline automatizado y completamente Serverless para descubrir, catalogar y consultar el historial de datos masivos mediante SQL, garantizando estrictas políticas de seguridad.

2. Requerimientos Técnicos del Proyecto (El Desafío)

2.1. PARTE I: Infraestructura Transaccional y Conectividad de Aplicaciones (Lab RDS)

Usted deberá levantar un motor relacional robusto para soportar las operaciones del día a día de la tienda web.

- **R1. Alta Disponibilidad Obligatoria:** Deberá aprovisionar una instancia de base de datos relacional administrada utilizando Amazon RDS. Para garantizar que el negocio no se detenga ante fallas de infraestructura, el motor debe configurarse con una implementación Multi-AZ (Multi-Availability Zones).
- **R2. Aislamiento y Redes de Seguridad:** Configurar los Grupos de Seguridad (Security Groups) de Amazon RDS de acuerdo al principio de menor privilegio.

Se debe denegar explícitamente el acceso público a internet y permitir únicamente conexiones entrantes originadas desde el servidor web de la aplicación en el puerto nativo del motor.

- **R3. Validación Operativa Extremo a Extremo:** Iniciar y configurar la aplicación web provista. El estudiante deberá demostrar la correcta conexión del aplicativo con la base de datos en la nube y realizar interacciones reales (escritura y lectura de registros de ventas) comprobando la persistencia de los datos.

Para esta etapa, deberá construir una PoC resolviendo el laboratorio **Ejercicio de laboratorio 5 - Creación de un servidor de bases de datos** del curso AWS Academy Cloud Foundations [177761].

2.2. PARTE II: Descubrimiento de Datos, Gobierno y Pipelines ETL (Lab AWS Glue)

Una vez asegurado el entorno transaccional, el candidato procesará el lago de datos históricos de la compañía.

- **R4. Orquestación e Inferencia Automatizada de Esquemas:** Configurar y desplegar un explorador de datos (AWS Glue Crawler) apuntando al repositorio de almacenamiento de origen. El Crawler debe ser capaz de analizar los archivos de forma autónoma, inferir de manera inteligente los tipos de datos y estructurarlos sin intervención manual.
- **R5. Construcción del Catálogo de Datos Centralizado:** Crear una base de datos lógica dentro del AWS Glue Data Catalog y poblarla con las tablas generadas automáticamente por el paso anterior, definiendo un esquema permanente para la organización.
- **R6. Automatización de la Infraestructura como Código (IaC):** Con el fin de hacer el pipeline replicable en otros países, el estudiante deberá desplegar un segundo AWS Glue Crawler utilizando una plantilla estandarizada de AWS CloudFormation.
- **R7. Auditoría de Seguridad y Menor Privilegio (IAM):** Analizar detalladamente las políticas de AWS Identity and Access Management (IAM) asignadas. El alumno debe validar que los usuarios analíticos cuenten estrictamente con los permisos necesarios para ejecutar el Crawler y consumir datos, limitando los accesos administrativos globales.
- **R8. Explotación Analítica Mediante SQL:** Conectar el motor Amazon Athena al Catálogo de Datos de Glue recién creado. El estudiante deberá ejecutar consultas SQL interactivas y complejas sobre los datos descubiertos para demostrar que la información es legible por el equipo de BI.
- **R9. Consumo Multi-Interfaz (AWS CLI y Resiliencia):**
 - Confirmar mediante la interfaz de comandos (AWS CLI) que el catálogo es accesible de forma segura de manera programática.

- Demostrar la resiliencia del pipeline forzando una mutación en los archivos de origen (Schema Evolution) y validando que el Crawler actualiza correctamente la estructura de las tablas analíticas al re-ejecutarse.

Con el fin de abordar esta etapa, deberá elaborar una PoC mediante la ejecución del laboratorio **Lab: Performing ETL on a Dataset by Using AWS Glue** del curso AWS Academy Data Engineering [177762].

3. Entregables

Los alumnos deberán consolidar y entregar un único informe técnico formal en formato **PDF**, el cual estará estructurado como una **Prueba de Concepto (Proof of Concept - PoC)** empresarial. El documento debe seguir rigurosamente el siguiente esquema de desarrollo:

ESTRUCTURA DEL INFORME TÉCNICO

ÍNDICE DE CONTENIDOS

1. Resumen Ejecutivo
2. Fase 1 (OLTP): Arquitectura Transaccional y Conectividad de Aplicaciones (PoC Lab RDS)
 - a) Diagrama de Arquitectura de la Fase 1
 - b) Diccionario de Componentes y Funciones
 - c) Evidencia de Implementación y Conectividad de la App
3. Fase 2 (OLAP): Pipeline ETL, Gobierno y Analítica Serverless (PoC Lab AWS Glue)
 - a) Diagrama de Arquitectura de la Fase 2
 - b) Diccionario de Componentes y Funciones
 - c) Evidencia de Catalogación, Automatización (IaC) y Consultas SQL (Athena)
4. Análisis de Seguridad y Cumplimiento Analítico (Políticas IAM)
5. Conclusiones Técnicas de la PoC

4. Rúbrica de evaluación

Sección 1: Resumen Ejecutivo e Introducción (Máximo: 0.5 puntos)

- 0.5 pts (Excelente): Contextualiza con éxito el negocio de *LatamBuy* e identifica claramente los objetivos de las fases transaccional (OLTP) y analítica (OLAP).

- 0.3 pts (Regular): Describe la empresa pero de forma vaga o confunde los objetivos analíticos con los operacionales.
- 0.0 pts (Insuficiente): No incluye introducción ni resumen ejecutivo.

Sección 2: Fase 1 (OLTP) - Arquitectura Transaccional y RDS (Máximo: 2.0 puntos)

- 2.0 pts (Excelente):
 - Incluye el diagrama de red con el aislamiento correcto (EC2 pública y RDS privada)
 - Detalla las funciones de cada componente de su arquitectura
 - Muestra captura de pantalla donde evidencie que obtuvo un 100 % del puntaje del laboratorio **Ejercicio de laboratorio 5 - Creación de un servidor de bases de datos** del curso AWS Academy Cloud Foundations [177761]. En caso de no lograr el 100 % del puntaje, deberá aportar como evidencia capturas de la base de datos en Multi-AZ conectada a la aplicación web.
- 1.0 pts (Regular): El diagrama o las explicaciones son incompletas, o falta alguna evidencia crítica (por ejemplo, configuró la base de datos en Single-AZ en lugar de Multi-AZ).
- 0.2 pts (Insuficiente): No hay diagramas legibles ni evidencias de que el laboratorio de RDS haya funcionado.

Sección 3: Fase 2 (OLAP) - Pipeline ETL y AWS Glue (Máximo: 2.0 puntos)

- 2.0 pts (Excelente):
 - Muestra el diagrama de flujo del dato completo (S3 → Crawler → Data Catalog → Athena).
 - Detalla las funciones de cada componente de su arquitectura
 - Muestra captura de pantalla donde evidencie que obtuvo un 100 % del puntaje del laboratorio **Lab: Performing ETL on a Dataset by Using AWS Glue** del curso AWS Academy Data Engineering [177762]. En caso de no lograr el 100 % del puntaje, deberá aportar como evidencia capturas de los AWS Glue crawler creados, AWS Glue database/table, Queries/Vista en Athena.
- 1.0 pts (Regular): El pipeline funciona pero omitió documentar el código de CloudFormation o los indicadores de rendimiento/escaneo de Athena.
- 0.2 pts (Insuficiente): No logró catalogar los datos, las capturas no corresponden o no presenta código de infraestructura.

Sección 4: Análisis de Seguridad IAM y Menor Privilegio (Máximo: 1.0 punto)

- 1.0 pt (Excelente): Presenta y audita las políticas de seguridad de la PoC. Argumenta con solidez técnica cómo se aplica el menor privilegio en Glue/Athena, detallando qué permisos se restringieron para proteger el Data Lake. Además, se incluye una explicación detallada del por qué se utilizan subredes públicas y privadas.
- 0.5 pts (Regular): Explica conceptualmente qué es IAM, pero no analiza ni incluye las políticas específicas que usó en sus laboratorios.
- 0.0 pts (Insuficiente): Ignora la sección de seguridad o propone políticas con acceso total de Administrador (*) o uso de una única subnet pública.

Sección 5: Conclusiones Técnicas y Formato (Máximo: 0.5 puntos)

- 0.5 pts (Excelente): Informe entregado en PDF bien estructurado, sin faltas de ortografía. Las conclusiones evalúan críticamente el ahorro de costos de Athena/Parquet y la alta disponibilidad de RDS.
- 0.2 pts (Regular): Cumple con el formato pero las conclusiones son muy genéricas o memorizadas, o presenta descuidos de redacción.
- 0.0 pts (Insuficiente): Formato desorganizado, fuera de plazo o sin conclusiones técnicas.

Consideraciones

- Solo se evaluarán los informes en **formato PDF** enviados por la plataforma **uvirtual**. Se ha habilitado un espacio para ello en el módulo 9 del Diplomado.
- Se descontará 1 punto por día de atraso en la entrega de la tarea. Debe asegurarse que la versión correcta de su tarea sea subida a la plataforma, cualquier modificación posterior a la fecha de entrega será considerado como atraso en la entrega.
- Se descontará 1 punto por cada error ortográfico en informe.
- Está permitido utilizar Inteligencias Artificiales (IA) para el desarrollo de la tarea, pero debe agregar el prompt utilizado como Anexo. En caso de no incluir el Anexo y si se detecta el uso de una IA se considerará su tarea como copia con nota mínima.

Fecha entrega: 26 Julio 2026