



DIPLOMADO EN DATA ENGINEERING · MODULO 10 - CAPÍTULO 1

Machine Learning para la Escala Masiva de Datos

Del dato a la decisión

Aplicando Machine Learning para resolver problemas empresariales mediante un caso de estudio real.

Eduardo Castillo Rodríguez

Máster en Inteligencia Artificial · Licenciado en Matemáticas y Computación
Consultor en Inteligencia Artificial y Analítica de Datos

¿Qué aprenderemos en este módulo?



Problema de negocio

Del dato a la decisión



Big Data y escalabilidad

Cuando los datos superan la capacidad humana



Plataformas modernas de datos

Data Warehouse, Data Lake, Lakehouse



Analytics y toma de decisiones

Descriptiva, Diagnóstica, Predictiva, Prescriptiva



Machine Learning

Modelos que aprenden de los datos



Laboratorio integrador

Proyecto real con dataset Corporación Favorita

CONCEPTO CLAVE

i Durante este capítulo construiremos el camino completo desde un problema de negocio hasta la construcción de modelos de Machine Learning utilizando un caso real.



¿Cuántas decisiones toma un supermercado mediano cada día?

Antes de comenzar — reflexiona un momento.

El dilema de las dos góndolas



Tienda Costanera

Estantes de leche vacíos. Clientes que se van sin comprar.



Tienda Maipú

Bodega llena. Leche que vence el jueves.

Dos tiendas. Mismo lunes. Mismo producto (leche). Dos realidades opuestas.

¿Cuál de las dos pierde dinero?

Las dos.

Desabastecimiento

Pierde ventas.

Sobrestock

Pierde producto.

El problema real

No es la leche — es la **decisión**.



¿Cómo sabe Netflix qué recomendar?

Cada vez que un usuario abre Netflix, la plataforma debe decidir qué contenido mostrar primero.

- **Historial de visualización**
- **Géneros preferidos**
- **Horario de consumo**
- **Dispositivo utilizado**
- **Comportamiento de usuarios con gustos similares**
- **Características del contenido**

❏ Netflix no adivina las preferencias de sus usuarios. Aprende de su comportamiento pasado para anticipar qué contenido tiene mayor probabilidad de consumir.



Personalización basada en datos

Todas estas organizaciones utilizan Machine Learning para anticipar los intereses de cada usuario y ofrecer recomendaciones personalizadas.



Netflix

Recomienda películas y series.



Spotify

Recomienda música.



Amazon

Recomienda productos.



YouTube

Recomienda videos.



El principio es siempre el mismo: aprender del comportamiento pasado para anticipar el comportamiento futuro.

¿Puede un supermercado hacer lo mismo?

Netflix predice

Qué quieres ver — para cada usuario, en cada momento.

Un supermercado puede predecir

Qué producto venderá, en qué tienda, en qué cantidad, en qué momento.



La lógica es exactamente la misma. Lo único que cambia es el problema de negocio.



La tecnología es la misma. Lo que cambia es el problema de negocio que queremos resolver.

Lunes. 08:00 AM. Dos llamadas.

 **Costanera**

"No tenemos leche."

 **Maipú**

"No cabe más leche en la bodega."

El mismo producto. El mismo día. Decisiones tomadas con los **mismos datos.**



¿Por qué falló la decisión?



Los datos existían.

Cada venta estaba registrada. Cada movimiento de inventario, documentado.

Faltaba capacidad analítica.

- A tiempo
- A escala
- Para cada tienda, cada producto, cada día

❏ Tener datos no es suficiente. La ventaja competitiva está en convertirlos en conocimiento accionable.

La demanda no depende de un solo factor



Precio

Variaciones propias y de la competencia



Promociones

Descuentos y ofertas activas



Clima

Temperatura y condiciones del día



Inventario

Stock disponible en tienda



Feriados

Días festivos y quincenas



Eventos locales

Partidos, conciertos, ferias



Competencia

Precios y disponibilidad del entorno



Precio del petróleo

Impacto indirecto en costos logísticos, transporte y comportamiento económico.

📌 Ningún analista puede procesar todas estas variables simultáneamente para 50.000 productos. Aquí es donde **Machine Learning** se vuelve indispensable.

¿Dónde viven los datos?

Cada venta comienza en el punto de venta.

¿A dónde va ese dato?

¿Cómo llega a un modelo de Machine Learning?



CONCEPTO CLAVE

SQL

¿Qué es?

Structured Query Language.
Lenguaje estándar para consultar y manipular bases de datos relacionales. Permite extraer, filtrar, agrupar y transformar datos almacenados en tablas.

¿Para qué sirve?

Es la primera capa de acceso a los datos transaccionales. Toda organización con un sistema de ventas tiene una base de datos SQL detrás.

En nuestro caso

Cada vez que un cliente pasa un producto por la caja en Corporación Favorita, esa venta queda registrada en una base de datos SQL. Es el punto de origen del dato — antes de que viaje por el pipeline, al Data Lake, y finalmente al modelo construido con Python y pandas.

Ya lo conoces — aquí lo ubicamos en el flujo completo.

CONCEPTO CLAVE

Pipeline de Datos

¿Qué es?

Secuencia automatizada de pasos que mueve, transforma y entrega datos desde una fuente hasta un destino. Cada paso del pipeline toma el resultado del anterior y lo prepara para el siguiente.

¿Para qué sirve?

Garantiza que los datos lleguen limpios, completos y a tiempo al lugar donde serán analizados o procesados por un modelo. Sin pipeline, los datos quedan atrapados en su origen.

En nuestro caso

El dato de la venta de leche en Costanera no llega solo al modelo de predicción. Pasa por un pipeline: se extrae de SQL, se limpia, se transforma, se carga al Data Lake y se procesa con Spark. Si un paso falla, la cadena se rompe.

CONCEPTO CLAVE

Data Lake

¿Qué es?

Repositorio centralizado que almacena grandes volúmenes de datos en su formato original — estructurados, semiestructurados y no estructurados — sin necesidad de definir su estructura de antemano.

¿Para qué sirve?

Permite acumular datos de múltiples fuentes (ventas, clima, inventario, redes sociales) sin transformarlos primero. La transformación ocurre cuando se necesita, no al momento de almacenar.

En nuestro caso

Todas las ventas de las 54 tiendas de Corporación Favorita, los datos de clima, los calendarios de feriados y los registros de inventario convergen en un Data Lake. Desde ahí, el pipeline los entrega listos para ser procesados con Python y pandas (polars) y alimentar el modelo de predicción.

Del código de barras al cliente satisfecho

1

Cliente → Caja

Registro en tiempo real

2

Base de Datos SQL

Estructuración del dato transaccional

3

Pipeline de Datos

Extracción, transformación y carga

4

Data Lake

Almacenamiento masivo centralizado

5

Python + pandas (polars)

Preparación y limpieza de datos

6

scikit-learn

Entrenamiento del modelo de ML

7

Predicción → Decisión

Valor real para el negocio

Una línea continua. Sin interrupciones. Sin datos perdidos.

❏ En escenarios de mayor escala, el paso de preparación puede realizarse con Apache Spark (PySpark) y Spark ML.

El colapso de la escala

1

5 productos

Manejable para un humano

2

500 productos

Difícil, pero posible

3

50.000 productos

Imposible para un humano

4

200 supermercados × cada día

Aquí nace Big Data.

Big Data

¿Qué es?

Conjunto de datos cuyo volumen, velocidad o variedad supera la capacidad de las herramientas tradicionales de procesamiento. No es solo "mucho dato" — es dato que no cabe en una hoja de cálculo ni en un servidor convencional.

¿Para qué sirve?

Permite almacenar, procesar y analizar información a una escala que sería imposible con bases de datos relacionales clásicas.

En nuestro caso

El supermercado genera millones de registros de ventas, inventario y comportamiento de clientes cada día. Eso es Big Data: demasiado para Excel, demasiado para un solo servidor, pero perfectamente manejable con las herramientas correctas.



Excel

Miles de filas. Un computador.



Base de datos relacional

Millones de registros. Consultas SQL.



Big Data

Cientos de millones de registros.
Procesamiento distribuido.

El problema no es solo la cantidad de datos — es la capacidad para procesarlos y analizarlos a tiempo.

Evolución de las plataformas de datos

¿Dónde se almacenan y administran todos estos datos?

Sistemas Operacionales

Sistemas transaccionales · Punto de origen de los datos

Data Warehouse

Datos estructurados · Reportes · Business Intelligence · SQL

Data Lake

Grandes volúmenes · Datos estructurados y no estructurados · Big Data · Machine Learning

Data Lakehouse

Analítica · Business Intelligence · Machine Learning · Inteligencia Artificial · Plataforma moderna

 La evolución de las plataformas de datos ha permitido integrar Business Intelligence, Machine Learning e Inteligencia Artificial sobre una misma infraestructura.

¿Qué arquitectura usar?

No existe una arquitectura universalmente mejor. La elección depende de las necesidades del negocio, el volumen de datos y los casos de uso. Actualmente, la tendencia es evolucionar hacia plataformas Lakehouse.

Característica	Data Warehouse	Data Lake	Data Lakehouse
Datos estructurados	✓	✓	✓
Datos no estructurados	□	✓	✓
Business Intelligence	✓	Parcial	✓
Machine Learning	Limitado	✓	✓
Escalabilidad	Media	Alta	Alta
Gobierno de datos	Alto	Medio	Alto
Casos de uso modernos	Limitados	Buenos	Excelente

Actualmente, muchas organizaciones están migrando hacia arquitecturas Lakehouse para integrar analítica, Machine Learning e Inteligencia Artificial en una única plataforma.

□ Plataformas de referencia: Microsoft Fabric · Databricks · Snowflake · Google BigQuery

❗ Las plataformas modernas permiten utilizar una misma infraestructura para Business Intelligence, Machine Learning e Inteligencia Artificial, eliminando la necesidad de mantener múltiples plataformas independientes.

Los datos existen. El problema también.

Cada venta

genera un registro

Cada registro

es un dato

Millones de datos


Pero los datos solos no toman decisiones.

Los datos ya existen. También sabemos dónde almacenarlos. Pero almacenar información no significa comprenderla.

¿Cómo transformar millones de datos en decisiones?



Del dato al aprendizaje automático



Machine Learning es una disciplina dentro de Analytics que permite construir modelos capaces de aprender patrones a partir de los datos para apoyar la toma de decisiones.

IDEA CLAVE

- ❗ Los datos por sí solos no generan valor. El valor aparece cuando somos capaces de transformarlos en conocimiento útil para decidir.

CONCEPTO CLAVE

Analytics

¿Qué es?

Proceso de examinar datos para descubrir patrones, extraer conclusiones y apoyar la toma de decisiones. Va desde la simple descripción de lo ocurrido hasta la recomendación automatizada de acciones.

¿Para qué sirve?


Transforma datos crudos en conocimiento accionable. Sin Analytics, los datos son solo ruido almacenado.

En nuestro caso

El supermercado tiene millones de registros de ventas. Analytics es lo que convierte esos registros en respuestas: ¿qué producto falla?, ¿por qué?, ¿qué pasará mañana?, ¿qué debemos pedir hoy?

Analytics: cuatro niveles de conocimiento


Cada nivel responde una pregunta más valiosa — y genera una acción más precisa.



Descriptiva

¿Qué pasó?


Las ventas de leche cayeron 30% el martes en Costanera.



Diagnóstica

¿Por qué pasó?

Feriado local + el proveedor no entregó a tiempo.



Predictiva

¿Qué va a pasar?


El próximo viernes habrá demanda +45% en Costanera.

Prescriptiva

¿Qué debo hacer?

Pedir 400 unidades el jueves antes de las 6 PM.

 Solo la analítica prescriptiva genera una acción concreta. Los tres niveles anteriores son el camino para llegar a ella.



NIVEL 1

Descriptiva: ¿Qué pasó?

"Las ventas de leche en Costanera aumentaron 40% el martes pasado."

Sabemos el **resultado**.

No sabemos por qué.

No sabemos qué hacer.

NIVEL 2

Diagnóstica: ¿Por qué pasó?

"Hubo un feriado local. El proveedor no entregó. La competencia bajó el precio."

Ahora **entendemos**.

Pero ya es **tarde para actuar**.



NIVEL 3

Predictiva: ¿Qué va a pasar?

 **17 Quincena**

Próximo viernes

 **+4°C**

Temperatura en alza


 **Partido**

Alta afluencia local

El modelo anticipa: demanda de leche **+40%** en Costanera. Ahora podemos actuar **antes**.



Storm Radar™



NIVEL 4

Prescriptiva: ¿Qué debo hacer?

1

Pide 400 unidades

El lunes antes de las 6 PM

2

Redistribuye 80 unidades

Desde Maipú a Costanera

3

Decisión ejecutada

Cliente satisfecho. Cero desperdicio.



La organización no solo sabe — **actúa**. Esto es Machine Learning aplicado a decisiones reales.

VARIABLE OBJETIVO

¿Qué queremos predecir?

La demanda futura de leche en cada tienda.

Esa será la variable objetivo que construiremos durante los laboratorios.

📋 Cada tienda. Cada producto. Cada día. Eso es lo que el modelo debe aprender a anticipar.

CONCEPTO CLAVE

Machine Learning

¿Qué es?

Rama de la inteligencia artificial que permite a los sistemas aprender patrones a partir de datos históricos y hacer predicciones o recomendaciones sobre datos nuevos — sin ser programados explícitamente para cada caso.

¿Para qué sirve?

Automatiza decisiones complejas que dependen de múltiples variables simultáneas. Cuanto más datos tiene, más preciso se vuelve. Escala donde el juicio humano no puede llegar.

En nuestro caso

El supermercado no puede tener un analista revisando manualmente 50.000 productos en 54 tiendas cada día. En esta clase construiremos modelos de Machine Learning con Python, pandas (polars) y scikit-learn sobre el dataset real de Corporación Favorita — el mismo problema, a escala real.

¿Quién hace posible un proyecto de Machine Learning?

Aunque solemos hablar de 'Machine Learning' como una única disciplina, en la práctica intervienen distintos perfiles que colaboran durante todo el ciclo de vida del proyecto.



Analista de Datos

Data Analyst

Responsabilidades principales

- Explora y comprende los datos.
- Identifica patrones y tendencias.
- Genera visualizaciones e indicadores.
- Comunica información para apoyar la toma de decisiones.



Científico de Datos

Data Scientist

Responsabilidades principales

- Formula el problema analítico.
- Diseña variables y modelos.
- Construye y evalúa modelos de Machine Learning.
- Interpreta los resultados para apoyar decisiones.



Ingeniero de Datos

Data Engineer

Responsabilidades principales

- Integra múltiples fuentes de datos.
- Diseña procesos ETL/ELT.
- Mantiene la infraestructura de datos.
- Garantiza la calidad y disponibilidad de la información.

CONCEPTO CLAVE

- i** Los roles representan funciones y responsabilidades dentro de un proyecto, no necesariamente cargos distintos dentro de una organización. En muchos proyectos, especialmente en pequeñas y medianas empresas, una misma persona puede desempeñar dos o más de estos roles en distintas etapas del ciclo de vida del proyecto. A medida que las organizaciones alcanzan una mayor madurez analítica, estas responsabilidades suelen distribuirse entre equipos especializados.

¿Cómo llevamos todo esto a un proyecto real?

Durante este capítulo construiremos un proyecto completo de Machine Learning utilizando un conjunto de datos empresarial real.



CONCEPTO CLAVE

i En este capítulo integraremos los conocimientos adquiridos durante el diplomado para desarrollar un proyecto completo de Machine Learning, siguiendo las mismas etapas utilizadas en proyectos profesionales de Ciencia de Datos.

El ciclo de vida de un proyecto de Machine Learning




CONCEPTO CLAVE

- i** Machine Learning corresponde solo a una etapa del proyecto. El mayor esfuerzo normalmente se concentra en comprender el problema de negocio y preparar adecuadamente los datos.

Nuestro proyecto durante este módulo

Durante este módulo trabajaremos sobre un único caso de estudio empresarial, recorriendo paso a paso todas las etapas de un proyecto real de Machine Learning.



Herramientas que utilizaremos durante el curso



Preparación de datos

Python · pandas



Modelo de regresión

Predicción de la demanda



Machine Learning

scikit-learn



Apoyo a la toma de decisiones

Del dato al valor de negocio



Durante este curso utilizaremos Python, pandas (polars) y scikit-learn para construir nuestros modelos de Machine Learning sobre datos reales.

¿Cómo evoluciona el flujo cuando los datos crecen?

Escenario	Procesamiento	Machine Learning
Datos pequeños y medianos	Python + pandas	scikit-learn
Datos grandes (un computador)	Polars	scikit-learn
Datos masivos (clúster distribuido)	Apache Spark (PySpark)	Spark ML

El proceso de Machine Learning es el mismo. Lo que cambia son las herramientas utilizadas para procesar los datos según su escala.

- 📄 En esta primera clase trabajaremos con Python, pandas (polars) y scikit-learn. Apache Spark y Spark ML son la evolución natural cuando el volumen de datos supera la capacidad de un único computador.



El Data Engineer: el habilitador invisible



Sin infraestructura de datos

→ No existe Analytics.



Sin Analytics

→ No existe Machine Learning.



Sin Machine Learning

→ No existen decisiones inteligentes.



El Data Engineer construye el **sistema nervioso** de la organización.

En esta clase: Python + pandas sobre el dataset de Corporación Favorita. En producción: pipelines automatizados sobre Data Lakes a escala.

Nuestro primer proyecto de Machine Learning

Durante el resto del diplomado trabajaremos sobre un mismo caso de estudio basado en una cadena de supermercados.

Un solo caso de estudio

Cada laboratorio desarrolla una nueva etapa del mismo proyecto.

Dataset empresarial real

No construiremos ejemplos artificiales.

Flujo profesional

Aplicaremos exactamente el mismo proceso utilizado en proyectos reales.

 Dataset Favorita (Kaggle) · Más de 23 millones de registros semanales · Variables de negocio reales: ventas históricas, promociones, tiendas, productos, precio del petróleo.

A partir de este punto dejaremos la teoría y comenzaremos a construir un proyecto real de Machine Learning paso a paso.



CASO REAL

Corporación Favorita

La cadena de supermercados más grande de Ecuador. Un dataset real.
Una competencia global en Kaggle.

El mismo problema que acabamos de describir — **a escala real**.

- ❏ La predicción precisa de demanda es uno de los temas más críticos en supply chain para habilitar la ejecución de los procesos downstream: planeación de inventario, distribución y logística.

La escala que cambia todo

125M

Registros de ventas

Si cada registro fuera una hoja de papel,
la pila mediría **12 km de altura**.

54

Tiendas

En todo Ecuador

33

Familias de productos

4 años de historia

Esto no se analiza en Excel.

📄 Dataset original extraído de Kaggle · Competencia: Corporación Favorita Grocery Sales Forecasting · kaggle.com/competitions/favorita-grocery-sales-forecasting

DATASET

Del problema al proyecto de Machine Learning

Para concentrarnos en los conceptos de Machine Learning, el dataset original ha sido adaptado y enriquecido.

Resumen Semanal

El dataset original, que contenía millones de registros diarios, ha sido **agregado y resumido a nivel semanal**. Esto nos permite trabajar con una escala más manejable sin perder la esencia de los patrones de venta.

Datos del Petróleo

Hemos **incorporado datos históricos del precio del petróleo**. Esta es una variable exógena crucial que, aunque no está directamente relacionada con las ventas de un supermercado, puede influir indirectamente en el consumo y la cadena de suministro en el país.

Esta preparación nos proporciona un conjunto de datos robusto y relevante para nuestro proyecto de predicción de demanda, reflejando un escenario más realista.



PROYECTO INTEGRADOR

Proyecto Integrador: Corporación Favorita

Aplicaremos todos los conceptos aprendidos durante el diplomado sobre un caso empresarial real.

Dataset

- Más de 23 millones de registros semanales
- 54 supermercados
- 4.036 productos
- Cinco años de historia
- Variables externas integradas

Variables disponibles

- Ventas históricas
- Promociones
- Precio del petróleo
- Calendario
- Tiendas y productos

Objetivo

Construir un modelo de Machine Learning capaz de anticipar el comportamiento futuro de las ventas utilizando datos históricos y variables explicativas.

CONCEPTO CLAVE

- ❶ Este laboratorio integra todos los conceptos estudiados durante el diplomado: ingeniería de datos, preparación de variables, análisis exploratorio, Machine Learning e interpretación de resultados.

Del dataset original al laboratorio


Para concentrarnos en los conceptos de Machine Learning, el dataset original ha sido adaptado y preparado especialmente para este módulo.

A partir del dataset original construimos un conjunto de datos optimizado para el laboratorio.

Característica	Dataset original (Kaggle)	Dataset del laboratorio
Volumen	125 millones de registros diarios	23,5 millones de registros semanales
Estructura	7 archivos independientes	1 archivo integrado
Tipo de datos	Datos transaccionales	Datos preparados para ML
Complejidad	Complejidad empresarial real	Complejidad adecuada para el laboratorio

 Dataset original: **Corporación Favorita Grocery Sales Forecasting** · kaggle.com/competitions/favorita-grocery-sales-forecasting

¿Cómo construiremos nuestro modelo?




❏ Durante el laboratorio seguiremos exactamente este flujo utilizando el conjunto de datos de Corporación Favorita.

Primer contacto: el dataset

No vamos a programar todavía. Vamos a **hacer preguntas**.

- ¿Cuáles son los productos con mayor variabilidad de demanda?
- ¿Qué tiendas tienen patrones más predecibles?
- ¿Qué variables explican mejor los picos de venta?

Los datos tienen respuestas. **Python, pandas y scikit-learn** son las herramientas para encontrarlas.



¿Qué aprenderemos durante el laboratorio?



Preparar datos

Limpieza, transformación e integración



Ingeniería de variables

Feature Engineering para Machine Learning



Entrenar modelos

Regresión con scikit-learn



Evaluar resultados

Métricas de desempeño del modelo



Interpretar métricas

Del número a la decisión de negocio



Cada etapa del laboratorio corresponde a una fase del ciclo de vida de un proyecto profesional de Machine Learning.

ML no existe para construir modelos.

Existe para ayudar a las organizaciones a tomar **mejores decisiones**.

La leche en el estante correcto, en la tienda correcta, en el momento correcto — eso es Machine Learning aplicado. Python, pandas y scikit-learn son el medio. La decisión de negocio es el fin.



 DESCARGA

Dataset del laboratorio

Descarga el conjunto de datos preparado especialmente para este módulo.



Dataset Corporación Favorita

Archivo integrado · 23,5 millones de registros · Listo para usar en Google Colab

[Descargar dataset →](#)



El archivo favorita_weekly_oil.parquet ya se encuentra integrado y preparado para Machine Learning. No requiere transformaciones adicionales para comenzar el laboratorio.