


Visualización de Datos de Alta Dimensionalidad con t-SNE

MÓDULO DE MACHINE LEARNING · DIPLOMADO DATA ENGINEER

Eduardo Castillo Rodríguez
Máster en Inteligencia Artificial

Dataset de ventas retail — **23 millones de registros**



¿Dónde terminamos la clase de PCA?

Elemento	Resultado obtenido
Dataset	Favorita Grocery Sales — 23 millones de transacciones
Unidad de análisis	Tienda + Semana
Matriz de características	2.322 observaciones × 5.000 variables
Normalización	Datos escalados mediante StandardScaler
Reducción	PCA aplicado — componentes principales obtenidos

Ahora debemos responder una nueva pregunta: **¿Cómo visualizar una matriz de 5.000 dimensiones?**

El Problema de la Visualización

POR QUÉ LA REPRESENTACIÓN NO ES SUFICIENTE

Tenemos una excelente representación para Machine Learning. Pero todavía no podemos comprender visualmente cómo se organizan las observaciones.

LO QUE TENEMOS

Matriz $2,322 \times 5,000$

Cada tienda-semana está perfectamente representada por las ventas de 5,000 productos.

Representación completa

Captura el comportamiento real de cada tienda. Ideal para entrenar modelos.

Pero...

5,000 dimensiones son imposibles de visualizar directamente.

LO QUE NECESITAMOS

Una proyección

Reducir 5,000 dimensiones a 2, conservando la estructura de los datos.

Que preserve vecindades

Las tiendas similares deben aparecer cerca en el mapa. Las tiendas distintas deben aparecer lejos.

Que sea interpretable

El resultado debe poder leerse visualmente sin conocer las 5,000 variables originales.

¿Qué hace realmente t-SNE?

REDUCCIÓN DE DIMENSIONALIDAD — SIN MATEMÁTICAS

t-SNE construye una representación bidimensional que intenta conservar las relaciones de vecindad entre observaciones similares.

En nuestro caso, t-SNE toma la matriz de 2,322 tiendas-semanas $\times$ 5,000 productos y produce un mapa en 2 dimensiones donde:

Tiendas similares aparecen cerca

Si dos tiendas tienen patrones de venta parecidos en los 5,000 productos, t-SNE las coloca próximas en el mapa.


Tiendas distintas aparecen lejos

Si dos tiendas tienen comportamientos muy diferentes, t-SNE las separa en el espacio bidimensional.

La similitud se mide en 5,000 dimensiones

t-SNE calcula las distancias en el espacio original de alta dimensionalidad, no en el mapa final.

t-SNE no explica las variables. Revela la estructura.



Visualización t-SNE del Caso Favorita

VISUALIZACIÓN GENERADA EN GOOGLE COLAB

Eje X

Primera dimensión t-SNE. Sin interpretación física directa.

Eje Y

Segunda dimensión t-SNE. Sin interpretación física directa.

Cada punto

Representa una observación tienda-semana. Total: 12.060 observaciones.


Color

Puede utilizarse para representar variables del negocio, como tienda, año, mes o cualquier otra característica de interés.

t-SNE organiza automáticamente las observaciones según la similitud de sus patrones de venta. Las agrupaciones representan vecindades locales de comportamiento, facilitando la exploración visual de datos de alta dimensionalidad.

Cómo leer el mapa t-SNE

INTERPRETACIÓN DE LAS LLAMADAS VISUALES



① Cercanía

Los puntos cercanos representan observaciones con patrones de venta similares.

② Agrupaciones

Los clusters indican grupos de observaciones con características semejantes.

③ Separación


Las regiones separadas reflejan distintos comportamientos presentes en los datos.

④ Exploración

t-SNE facilita descubrir patrones sin conocer previamente las categorías existentes.

t-SNE no clasifica automáticamente los datos; proporciona una representación visual que facilita descubrir estructuras, grupos y posibles comportamientos atípicos.

Mapa t-SNE de las observaciones tienda-semana



Qué NO interpretar en un mapa t-SNE

ERRORES FRECUENTES AL INTERPRETAR UN MAPA T-SNE

✗ Los ejes no tienen significado físico

Las dimensiones t-SNE no representan variables del negocio, productos ni componentes principales. Son únicamente coordenadas utilizadas para construir la visualización.

✗ No interpretar las distancias globales

La separación entre regiones lejanas no representa una medida cuantitativa exacta de diferencia. t-SNE preserva principalmente las relaciones locales entre observaciones.

✓ Lo realmente importante

Interpreta únicamente las vecindades locales: los puntos cercanos suelen representar observaciones con patrones de venta similares.

t-SNE es una herramienta de exploración visual. Su objetivo es facilitar el descubrimiento de estructuras y patrones en datos de alta dimensionalidad, no proporcionar una representación geométrica exacta del espacio original de los datos.

Lo que NO debemos interpretar

LIMITACIONES DEL MAPA T-SNE

t-SNE es una herramienta poderosa, pero sus resultados pueden inducir a error si no se conocen sus limitaciones.

INTERPRETACIONES INCORRECTAS

Los ejes no tienen significado físico

El eje X y el eje Y no representan variables del negocio. No tienen unidades ni interpretación directa.

Las distancias globales pueden ser engañosas

Dos grupos que parecen cercanos en el mapa pueden estar muy lejos en el espacio original de 5,000 dimensiones.

El tamaño de un grupo no implica importancia

Un grupo grande no necesariamente representa más tiendas o más ventas. Depende de los parámetros del algoritmo.

REGLA DE ORO

t-SNE es una herramienta de exploración, no de confirmación.

Úsalo para generar hipótesis

El mapa sugiere estructura. La estructura debe validarse con análisis adicionales.

No uses t-SNE para medir distancias

Las distancias en el mapa 2D no son métricas confiables del espacio original.

Los resultados dependen de los parámetros

Cambiar la perplejidad (perplexity) puede producir mapas visualmente muy diferentes.

PCA y t-SNE

DOS HERRAMIENTAS, DOS OBJETIVOS DISTINTOS

PCA y t-SNE no son algoritmos rivales. Resuelven problemas distintos dentro del mismo pipeline de análisis.

Dimensión	PCA	t-SNE
Objetivo	Reducir dimensionalidad preservando varianza	Visualizar estructura preservando vecindades
Salida	k componentes principales	2 o 3 dimensiones
Uso principal	Preprocesamiento para modelos	Exploración visual
Interpretabilidad	Componentes explicables (% varianza)	Ejes sin significado físico
Entrada para modelos	Sí — directamente	No recomendado
Visualización	Limitada (primeros 2 componentes)	Diseñado para visualizar

Dos Herramientas dentro del Mismo Pipeline

PCA puede utilizarse antes de t-SNE para acelerar el procesamiento en datasets grandes, pero ambas técnicas pueden utilizarse de manera independiente dependiendo del objetivo del análisis.

EL PIPELINE COMPLETO



¿CUÁNDO USAR CADA UNO?

Solo PCA

Cuando el objetivo es reducir dimensionalidad para entrenar un modelo predictivo.

Solo t-SNE

Cuando el objetivo es explorar visualmente la estructura del dataset sin entrenar un modelo.

PCA + t-SNE

Cuando el dataset es muy grande. PCA reduce primero a ~50-100 dimensiones, luego t-SNE proyecta a 2D de forma más eficiente.

Lo que implementaremos en Google Colab

SESIÓN PRÁCTICA — FLUJO COMPLETO



i El resultado será un mapa visual de 2,322 puntos donde cada punto representa una tienda durante una semana. Podremos colorear los puntos por variables externas para interpretar la estructura.

"El Machine Learning comienza mucho antes del primer algoritmo."

El mito

El valor está en **elegir el algoritmo correcto** — PCA, t-SNE, clustering, redes neuronales.

La realidad

El valor está en **construir la representación correcta** — definir la observación, construir la matriz, escalar los datos.

Lo que aprendimos

Partimos de 23 millones de transacciones y construimos una representación que permite visualizar el comportamiento de 2,322 tiendas-semanas en 2 dimensiones.

La lección central

El objetivo no era aprender un algoritmo. Era comprender cómo explorar y visualizar datos de muy alta dimensionalidad usando el mismo caso de estudio trabajado durante todo el módulo.