


Reducción de Dimensionalidad con UMAP

MÓDULO DE MACHINE LEARNING · DIPLOMADO DATA ENGINEER

Eduardo Castillo Rodríguez
Máster en Inteligencia Artificial

Dataset de ventas retail — **23 millones de registros**



¿Dónde terminamos la clase de PCA?

Elemento	Resultado obtenido
Dataset	Favorita Grocery Sales — 23 millones de transacciones
Unidad de análisis	Tienda + Semana
Matriz de características	2.322 observaciones × 5.000 variables
Normalización	Datos escalados mediante StandardScaler
Reducción	PCA aplicado — componentes principales obtenidos

Ahora debemos responder una nueva pregunta: **¿Existe una alternativa más rápida y moderna para visualizar datos de alta dimensionalidad?**

El Problema de la Visualización

POR QUÉ LA REPRESENTACIÓN NO ES SUFICIENTE

Tenemos una excelente representación para Machine Learning. Pero todavía no podemos comprender visualmente cómo se organizan las observaciones.

LO QUE TENEMOS

Matriz $2,322 \times 5,000$

Cada tienda-semana está perfectamente representada por las ventas de 5,000 productos.

Representación completa

Captura el comportamiento real de cada tienda. Ideal para entrenar modelos.

Pero...

5,000 dimensiones son imposibles de visualizar directamente.

LO QUE NECESITAMOS

Una proyección

Reducir 5,000 dimensiones a 2, conservando la estructura de los datos.

Que preserve vecindades

Las tiendas similares deben aparecer cerca en el mapa. Las tiendas distintas deben aparecer lejos.

Que sea interpretable

El resultado debe poder leerse visualmente sin conocer las 5,000 variables originales.


¿Qué es UMAP?

REDUCCIÓN DE DIMENSIONALIDAD — INTUICIÓN PRÁCTICA

UMAP (Uniform Manifold Approximation and Projection) es una técnica moderna de reducción de dimensionalidad no lineal que transforma datos con miles de variables en una representación de pocas dimensiones, preservando la estructura de los datos tanto a nivel local como, en gran medida, a nivel global.

Fue desarrollada para ofrecer una alternativa más rápida y escalable que t-SNE, manteniendo una excelente capacidad para visualizar patrones complejos en grandes volúmenes de datos.

EL FLUJO DE UMAP



¿POR QUÉ UMAP?

- ✓ Reducción no lineal**
Captura estructuras complejas que métodos lineales como PCA no pueden representar.
- ✓ Preserva estructura local y global**
Mantiene vecindades locales y, en mayor medida que t-SNE, la estructura global.
- ✓ Velocidad superior**
Considerablemente más rápido que t-SNE en datasets grandes.
- ✓ Escalable**
Diseñado para funcionar bien con millones de observaciones.
- ✓ Versátil**
Puede usarse para visualización y como preprocesamiento para modelos.

UMAP busca representar los datos en dos dimensiones manteniendo, en la medida de lo posible, la forma y organización del espacio original.

Visualización UMAP del Caso Favorita

VISUALIZACIÓN GENERADA EN GOOGLE COLAB

Eje UMAP 1

Primera dimensión latente generada por UMAP. No posee una interpretación física directa.

Eje UMAP 2

Segunda dimensión generada por UMAP para preservar la estructura de similitud entre las observaciones.


Cada punto

Corresponde a una observación del conjunto de datos. Cada punto representa una combinación tienda-semana.

Color


Puede utilizarse para representar variables del negocio, como tienda, año, mes o cualquier otra característica de interés.

UMAP permite identificar rápidamente grupos de observaciones con comportamientos similares, facilitando el análisis exploratorio de grandes volúmenes de datos.



Cómo leer un mapa UMAP

INTERPRETACIÓN DE LAS CLAVES VISUALES



① Cercanía

Observaciones cercanas en el mapa suelen presentar características similares en el espacio original de alta dimensionalidad.

② Agrupaciones

Los grupos representan observaciones con comportamientos parecidos, facilitando la identificación de segmentos o patrones en los datos.


③ Separación

Las regiones alejadas corresponden a grupos con características diferentes, permitiendo distinguir distintos perfiles presentes en el conjunto de datos.

④ Posible Anomalia

UMAP facilita descubrir relaciones, tendencias y posibles anomalías antes de construir modelos de Machine Learning.

UMAP transforma miles de variables en una representación visual intuitiva, facilitando el análisis exploratorio de datos complejos.



Qué NO interpretar en un mapa UMAP

ERRORES FRECUENTES AL INTERPRETAR UN MAPA UMAP

✗ Los ejes no tienen significado físico

Los ejes UMAP 1 y UMAP 2 son dimensiones construidas por el algoritmo. No representan variables originales del conjunto de datos ni tienen una interpretación de negocio directa.

✗ No interpretar las distancias globales como medidas exactas

Aunque UMAP preserva mejor la estructura global que t-SNE, las distancias entre grupos alejados no representan una medida exacta de similitud. El análisis debe centrarse en la organización general y en las relaciones entre observaciones cercanas.

✓ Lo realmente importante

Utilice UMAP para descubrir patrones, identificar agrupaciones, detectar anomalías y comprender mejor la organización general de los datos antes de construir modelos predictivos.

UMAP es una herramienta de exploración visual. Su principal objetivo es facilitar la comprensión de la estructura de datos de alta dimensionalidad, no medir distancias exactas.

¿Cuál técnica utilizar?

COMPARATIVA — PCA · T-SNE · UMAP

No existe una técnica mejor en todos los casos. La elección depende del objetivo del análisis y del tamaño del conjunto de datos.

Característica	PCA	t-SNE	UMAP
Tipo	Lineal	No lineal	No lineal
Objetivo principal	Reducir dimensionalidad	Visualización	Visualización
Estructura local	★★	★★★★★★	★★★★★★
Estructura global	★★★★★	★★	★★★★★
Velocidad	★★★★★★	★★	★★★★★
Escalabilidad	Excelente	Limitada	Excelente
Interpretabilidad	Alta	Baja	Baja
Uso típico	Preprocesamiento y modelado	Exploración visual en datasets medianos	Exploración visual en grandes volúmenes

Utilice PCA cuando...

Quiera reducir variables antes de entrenar modelos. Necesite conservar la mayor parte de la información. La interpretabilidad de los componentes sea importante.

Utilice t-SNE cuando...

Necesite una visualización de alta calidad. Trabaje con conjuntos de datos medianos. Quiera descubrir agrupaciones locales con precisión.

Utilice UMAP cuando...


Trabaje con grandes volúmenes de datos. Requiera mayor velocidad de procesamiento. Desea preservar tanto relaciones locales como buena parte de la estructura global.

Pipeline de análisis con reducción de dimensionalidad

DEL DATO ORIGINAL AL ANÁLISIS EXPLORATORIO

La reducción de dimensionalidad constituye una etapa de apoyo para comprender la estructura de los datos antes de aplicar modelos de Machine Learning.

EL PIPELINE COMPLETO



¿CUÁNDO APLICAR CADA TÉCNICA?

PCA

Cuando el objetivo es reducir variables para entrenar modelos predictivos. Rápido, lineal e interpretable.

t-SNE

Cuando se necesita una visualización de alta calidad en datasets medianos. Excelente para descubrir agrupaciones locales.

UMAP

Cuando se trabaja con grandes volúmenes de datos. Más rápido que t-SNE y preserva mejor la estructura global.

Conclusiones

✓ La reducción de dimensionalidad facilita el análisis

Permite explorar y comprender datos con miles de variables que no pueden visualizarse directamente.

✓ PCA, t-SNE y UMAP son técnicas complementarias

Cada una resuelve un problema distinto dentro del mismo pipeline de análisis.

✓ UMAP destaca por velocidad y escalabilidad

Combina rapidez, escalabilidad y una excelente capacidad de visualización para grandes volúmenes de datos.

✓ La técnica adecuada depende del problema

La elección depende del objetivo del análisis, el tamaño del dataset y si se requiere interpretabilidad.

✓ La interpretación requiere conocimiento del negocio

Los resultados visuales siempre deben complementarse con el contexto y el conocimiento del dominio.

Visualizar correctamente los datos es el primer paso para descubrir patrones, generar conocimiento y construir mejores modelos de Machine Learning.