

Introducción a MLOps


CAPÍTULO 6 · DIPLOMADO DATA ENGINEER

Del desarrollo de modelos al despliegue en producción

Eduardo Castillo Rodríguez

Máster en Inteligencia Artificial

¿Cómo llevar un modelo de Machine Learning a producción?



Objetivos del capítulo

Al finalizar esta sesión el estudiante será capaz de:



Comprender MLOps

Entender qué es MLOps y por qué es fundamental en proyectos de Machine Learning



Ciclo de vida del modelo

Identificar las etapas del ciclo de vida de un modelo de Machine Learning



Rol del Data Engineer

Comprender el rol del Data Engineer en un proyecto de Machine Learning



Desafíos del despliegue

Reconocer los principales desafíos del despliegue de modelos en producción



Herramientas de MLOps

Conocer herramientas ampliamente utilizadas en el ecosistema MLOps




Del laboratorio a producción

Comprender cómo llevar un modelo desde el desarrollo hasta su uso real

¿Qué ocurre después de entrenar un modelo?

Entrenar un modelo no significa que esté listo para ser utilizado por una organización. Existe un largo camino entre el laboratorio y la producción.



Un modelo que no está en producción no genera valor. MLOps es el puente entre el laboratorio y el mundo real.



¿Qué es MLOps?

MLOps (Machine Learning Operations) es el conjunto de prácticas que permiten desarrollar, desplegar, monitorear y mantener modelos de Machine Learning de forma confiable, automatizada y reproducible.

MLOps surge de la necesidad de aplicar principios de ingeniería de software al ciclo de vida completo de los modelos de Machine Learning.



Data Engineering

Gestión, transformación y disponibilidad de los datos



Machine Learning

Desarrollo, entrenamiento y evaluación de modelos




DevOps

Automatización, despliegue y operación de sistemas

❏ La intersección de estas tres disciplinas define MLOps.

Ciclo de vida de un modelo

Un modelo de Machine Learning no es un producto estático. Su ciclo de vida es continuo e iterativo, desde la obtención de datos hasta el reentrenamiento en producción.



El proceso es continuo: el monitoreo alimenta el reentrenamiento, cerrando el ciclo.

Rol del Data Engineer

El Data Engineer es el responsable de garantizar que los datos y los modelos estén disponibles, integrados y funcionando correctamente en los sistemas productivos.

Etapas	Responsabilidad del Data Engineer
Datos	Construcción y mantenimiento de pipelines de datos
Preparación	Garantía de calidad, limpieza y transformación
Entrenamiento	Disponibilidad y acceso eficiente a los datos
Despliegue	Integración del modelo con los sistemas productivos
Producción	Automatización de flujos y procesos
Monitoreo	Seguimiento del desempeño y detección de anomalías

"El Data Engineer conecta los modelos con los sistemas productivos. Sin datos confiables, no hay modelo confiable."

Principales desafíos

Llevar un modelo a producción implica superar obstáculos técnicos y organizacionales que van mucho más allá del entrenamiento.



Calidad de datos

Datos inconsistentes o incompletos afectan directamente el desempeño del modelo en producción



Versionamiento

Gestionar versiones de datos, código y modelos de forma coordinada y trazable



Reproducibilidad

Garantizar que los experimentos puedan replicarse con los mismos resultados



Escalabilidad

Diseñar sistemas capaces de manejar grandes volúmenes de datos y solicitudes



Monitoreo

Detectar degradación del modelo o cambios en la distribución de los datos (data drift)



Reentrenamiento

Actualizar el modelo de forma automatizada cuando su desempeño disminuye

¿Cómo responde MLOps a estos desafíos?

Cada desafío del ciclo de vida posee herramientas y prácticas específicas para resolverlo.

Desafío	Solución habitual
Calidad de datos	Pipelines de datos
Versionamiento	Git + DVC
Reproducibilidad	Docker
Despliegue	FastAPI
Automatización	Airflow
Monitoreo	MLflow

Las herramientas de MLOps existen para resolver problemas concretos del ciclo de vida de un modelo, no simplemente para agregar complejidad al proyecto.

Herramientas de MLOps

El ecosistema MLOps agrupa sus herramientas por función dentro del ciclo de vida del modelo.



Versionamiento

Git · DVC

Control de versiones para código, datos y modelos.



Contenedores

Docker

Empaquetar aplicaciones para ejecutarlas de forma idéntica en cualquier entorno.



Orquestación

Kubernetes

Administrar y escalar contenedores automáticamente.



Experimentación

MLflow

Registrar experimentos, métricas y versiones de modelos.



Automatización

Airflow

Orquestar pipelines de datos y procesos automáticos.



Serving

FastAPI

Publicar modelos de Machine Learning como servicios web (API).




No es necesario dominar todas estas herramientas. Lo importante es comprender qué problema resuelve cada una dentro del ciclo de vida de un modelo.



Flujo completo de un proyecto

Un proyecto de Machine Learning en producción sigue un flujo continuo que integra ingeniería de datos, modelado y operaciones.



"El proceso es continuo. En MLOps, el despliegue no es el final: es el comienzo de la operación."

Conclusiones



Un buen modelo no es suficiente

El entrenamiento es solo el punto de partida. El valor real se genera en producción.



Los modelos deben mantenerse

Sin monitoreo y reentrenamiento, los modelos se degradan con el tiempo.



Del laboratorio a producción

MLOps permite llevar modelos desde el desarrollo hasta su uso real de forma confiable.



El Data Engineer es clave

Cumple un rol fundamental en la integración de datos, modelos y sistemas productivos.



Integración como base

La integración entre datos, modelos y sistemas es la base de los proyectos modernos de IA.



"El éxito de un proyecto de Machine Learning no depende únicamente de construir un buen modelo, sino de mantenerlo funcionando correctamente en producción."



"Entrenar un modelo es solo el comienzo. El verdadero desafío consiste en mantenerlo funcionando correctamente en producción."



Arquitectura simplificada de un proyecto de Machine Learning

Un proyecto de ML en producción integra múltiples capas: datos, ingeniería, modelado y operaciones.



☐ MLflow actúa de forma transversal: registra experimentos, métricas y versiones del modelo a lo largo de todo el ciclo.


“

"MLOps integra datos, modelos y operaciones para mantener soluciones de Inteligencia Artificial funcionando de manera continua en producción."

”

El camino recorrido durante el diplomado

Cada capítulo del diplomado representa una pieza fundamental del ciclo de vida de un proyecto de Machine Learning. Juntas, forman una visión completa e integrada.



“

"Estas piezas no son independientes: forman el ciclo de vida completo de un proyecto de Machine Learning moderno."

”

Gracias

Diplomado en Data Engineering · Machine Learning con Big Data

¡Felicitaciones por completar este recorrido!

- Reducción de dimensionalidad
- Modelos supervisados
- Modelos no supervisados
- Overfitting y generalización
- Validación cruzada
- Optimización de hiperparámetros
- MLOps y despliegue en producción



"La Inteligencia Artificial no termina cuando un modelo obtiene una buena métrica. Comienza cuando ese modelo entrega valor real en producción."



Eduardo Castillo Rodríguez

Máster en Inteligencia Artificial

Profesor Universitario

