


Generalización, Underfitting y Overfitting

MÓDULO DE MACHINE LEARNING · DIPLOMADO DATA ENGINEER

Eduardo Castillo Rodríguez

Máster en Inteligencia Artificial

Cómo construir modelos que aprendan patrones y no memoricen los datos.



Objetivos del capítulo

Al finalizar esta sesión el estudiante será capaz de:



Generalización

Comprender el concepto de generalización en Machine Learning.



Underfitting y Overfitting

Diferenciar ambos problemas y sus causas.



Sesgo y Varianza

Explicar el sesgo y la varianza como conceptos fundamentales.



Trade-off Bias-Variance

Interpretar el equilibrio entre sesgo y varianza.



Buena Generalización

Identificar cuándo un modelo generaliza correctamente.

¿Por qué no basta con entrenar un modelo?



El objetivo real

El Machine Learning no busca memorizar los datos de entrenamiento, sino aprender patrones que funcionen sobre datos nunca vistos.




El riesgo de memorizar

Un modelo que memoriza los datos de entrenamiento puede tener un rendimiento perfecto en entrenamiento pero fallar completamente en producción.



Generalización

La capacidad de un modelo para desempeñarse bien sobre datos nuevos se llama generalización. Es el criterio más importante para evaluar un modelo.



¿Qué es la generalización?



Definición formal

La generalización es la capacidad de un modelo entrenado para producir predicciones correctas sobre datos nuevos que no formaron parte del conjunto de entrenamiento.




Ejemplo sencillo

Un modelo entrenado para detectar spam con correos de 2020 debe seguir funcionando correctamente con correos de 2024, aunque el lenguaje y los patrones hayan cambiado.



Idea clave

Un modelo que generaliza bien no memoriza: aprende la estructura subyacente de los datos. La diferencia entre memorizar y aprender es la esencia del Machine Learning.



¿Cómo saber si un modelo aprende correctamente?

Existen tres situaciones posibles al evaluar el comportamiento de un modelo:

Situación	Entrenamiento	Datos nuevos
Buen modelo	Buen desempeño	Buen desempeño
Underfitting	Bajo desempeño	Bajo desempeño
Overfitting	Excelente desempeño	Bajo desempeño

El objetivo del Machine Learning no es obtener el mejor resultado sobre el entrenamiento, sino mantener un buen rendimiento sobre datos nunca vistos.

Underfitting

El underfitting ocurre cuando el modelo es demasiado simple para capturar los patrones presentes en los datos. El modelo no aprende lo suficiente ni del conjunto de entrenamiento.

Características	Síntomas	Consecuencias
Modelo demasiado simple	Error alto en entrenamiento	Predicciones imprecisas
Capacidad insuficiente	Error alto en validación	No es útil en producción
Alto sesgo (bias)	Curvas de aprendizaje planas	Requiere mayor complejidad
Pocas características o épocas	Rendimiento similar en train y test	Subajuste del modelo

Causas más comunes

- Modelo demasiado simple.
- Muy pocas variables.
- Muy pocas épocas de entrenamiento.
- Regularización excesiva.




Overfitting

El overfitting ocurre cuando el modelo es demasiado complejo y aprende no solo los patrones, sino también el ruido y las particularidades del conjunto de entrenamiento.

Características	Síntomas	Consecuencias
Modelo demasiado complejo	Error muy bajo en entrenamiento	Falla en datos nuevos
Memoriza los datos de entrenamiento	Error alto en validación	No generaliza
Alta varianza	Gran diferencia entre train y test	Inútil en producción
Demasiados parámetros o épocas	Sensible a pequeñas variaciones	Sobreajuste del modelo

Causas más comunes

- Modelo demasiado complejo.
- Exceso de parámetros.
- Demasiadas épocas.
- Muy pocos datos.
- Presencia de ruido.



Underfitting vs Overfitting

Ambos problemas impiden que el modelo generalice correctamente, pero por razones opuestas.

	Underfitting	Overfitting
Complejidad del modelo	Demasiado simple	Demasiado complejo
Sesgo (Bias)	Alto	Bajo
Varianza	Baja	Alta
Error en entrenamiento	Alto	Muy bajo
Error en prueba	Alto	Alto
Generalización	No generaliza	No generaliza
Solución	Aumentar complejidad	Reducir complejidad / regularizar
Diagnóstico	No aprende	Memoriza los datos

Sesgo y Varianza

El sesgo y la varianza son las dos fuentes principales de error en un modelo de Machine Learning.

Sesgo (Bias): Error producido por un modelo demasiado simple que no logra capturar el patrón real.

Varianza: Error producido por un modelo demasiado sensible a pequeñas variaciones del conjunto de entrenamiento.

Concepto	Sesgo (Bias)	Varianza
Definición	Error por suposiciones incorrectas del modelo	Error por sensibilidad excesiva a los datos de entrenamiento
Causa	Modelo demasiado simple	Modelo demasiado complejo
Efecto	Underfitting	Overfitting
Error en entrenamiento	Alto	Bajo
Error en prueba	Alto	Alto
Analogía (diana)	Disparos alejados del centro	Disparos dispersos entre sí



Alto Sesgo, Baja Varianza

Las predicciones son consistentes entre sí, pero sistemáticamente alejadas del valor verdadero.



¿Qué ocurre?


El modelo comete siempre el mismo tipo de error. Las predicciones son estables pero incorrectas.



Ejemplo típico

Modelo lineal tratando de ajustarse a datos no lineales. Underfitting clásico: el modelo es demasiado simple para capturar el patrón real.

En la diana: los disparos caen agrupados, pero lejos del centro. Alta consistencia, baja precisión.



Bajo Sesgo, Alta Varianza

Las predicciones están cerca del valor verdadero en promedio, pero son muy dispersas e inconsistentes.



¿Qué ocurre?


El modelo es sensible a pequeñas variaciones en los datos de entrenamiento. Cada vez que se entrena, produce resultados diferentes.



Ejemplo típico

Modelo demasiado complejo que memoriza el ruido del entrenamiento. Overfitting clásico: funciona bien en entrenamiento pero falla en datos nuevos.

En la diana: los disparos rodean el centro pero están muy dispersos. Alta precisión promedio, baja consistencia.



Bajo Sesgo, Baja Varianza

Las predicciones son precisas y consistentes. Este es el escenario ideal: el modelo generaliza correctamente.



¿Qué ocurre?


El modelo aprende el patrón real de los datos sin memorizar el ruido. Las predicciones son estables y correctas en datos nuevos.



Modelo ideal

Complejidad justa. Captura los patrones reales sin sobreajustar. El modelo alcanza el mejor equilibrio entre sesgo y varianza, logrando el menor error de generalización y un excelente desempeño sobre datos nuevos.

En la diana: los disparos caen agrupados en el centro. Alta precisión y alta consistencia. El objetivo del Machine Learning.



Tres escenarios principales

Combinando sesgo y varianza obtenemos tres situaciones clave. Solo una de ellas representa un modelo que generaliza correctamente.

Escenario	Sesgo	Varianza	Comportamiento	Diagnóstico
Alto Sesgo, Baja Varianza	Alto	Baja	Predicciones consistentes pero incorrectas	Underfitting
Bajo Sesgo, Alta Varianza	Bajo	Alta	Predicciones dispersas, inestables	Overfitting
Bajo Sesgo, Baja Varianza	Bajo	Baja	Predicciones precisas y consistentes	✔ Modelo ideal

El objetivo del entrenamiento es encontrar el punto de equilibrio donde tanto el sesgo como la varianza sean mínimos.

Trade-off Bias–Variance

El trade-off Bias–Variance describe la tensión fundamental entre sesgo y varianza: reducir uno tiende a aumentar el otro.



Baja complejidad

Domina el sesgo. El modelo es demasiado simple y comete errores sistemáticos.



Zona óptima ✓

El error de validación es mínimo. Aquí el modelo alcanza su mejor capacidad de generalización.




Alta complejidad

Domina la varianza. El modelo memoriza el entrenamiento y falla con datos nuevos.



Error total

Error total = sesgo² + varianza + ruido irreducible. El objetivo es minimizar esta suma.



Ejemplo conceptual: tres modelos

Sobre el mismo conjunto de datos, tres modelos con distinta complejidad producen resultados muy diferentes.



Underfitting

Modelo lineal simple. No captura la curvatura real de los datos. Error alto en entrenamiento y en prueba.

✗ *No aprende el patrón.*



Modelo adecuado

Modelo con complejidad justa. Captura el patrón real sin memorizar el ruido. Generaliza correctamente.


✓ *Aprende el patrón y generaliza.*



Overfitting

Modelo polinomial de grado muy alto. Pasa por cada punto de entrenamiento pero falla completamente en datos nuevos.

✗ *Memoriza el entrenamiento y falla con datos nuevos.*



Conclusiones

Las ideas fundamentales que debemos recordar de esta sesión:



El objetivo es generalizar

El Machine Learning busca aprender patrones, no memorizar datos.



Más complejidad no implica un mejor modelo

La complejidad debe ajustarse al problema y a los datos disponibles.



El overfitting aparece cuando el modelo memoriza

Un modelo sobreajustado falla con datos nuevos aunque funcione bien en entrenamiento.



El equilibrio Bias–Variance produce mejores modelos

Reducir sesgo y varianza simultáneamente es el desafío central del diseño de modelos.



La siguiente etapa: comprobar la generalización

Aprenderemos cómo verificar objetivamente que un modelo realmente generaliza.

Laboratorio: Observando el Overfitting en acción

Hasta ahora hemos visto estos conceptos desde un punto de vista teórico. En el laboratorio veremos cómo cambia el comportamiento de un modelo al aumentar su complejidad y cómo identificar visualmente el underfitting, el overfitting y la zona de mejor generalización.



Herramienta

Google Colab con Python y scikit-learn.



¿Qué observaremos?

Cómo varía el error de entrenamiento y validación al aumentar la complejidad del modelo.



Objetivo

Identificar visualmente la zona de mejor generalización en un modelo de regresión polinómica.

