


Validación Cruzada (Cross Validation)

CAPÍTULO 5 · DIPLOMADO DATA ENGINEER

Eduardo Castillo Rodríguez

Máster en Inteligencia Artificial

¿Cómo evaluar correctamente un modelo de Machine Learning?



Objetivos del capítulo

Al finalizar esta sesión el estudiante será capaz de:



Limitaciones del Hold-Out

Comprender las limitaciones de una única partición Train/Test



K-Fold Cross Validation

Explicar el funcionamiento de K-Fold Cross Validation



Interpretación de resultados

Interpretar correctamente los resultados obtenidos mediante validación cruzada



Hold-Out vs K-Fold

Comparar ambas estrategias de evaluación



Cuándo usar cada estrategia

Comprender cuándo utilizar cada estrategia según el contexto



Evaluación confiable

Aplicar validación cruzada para obtener estimaciones robustas del modelo

¿Podemos confiar en una única partición Train/Test?

PRIMERA DIVISIÓN

Train 80%

Test 20%

$R^2 = 0.94$

SEGUNDA DIVISIÓN

Train 80%

Test 20%

$R^2 = 0.79$



Ambos modelos utilizaron exactamente el mismo algoritmo y los mismos datos. ¿Por qué obtuvieron resultados diferentes?



El resultado depende de cómo fueron divididos los datos.

Hold-Out

La estrategia más simple: dividir los datos una única vez en entrenamiento y prueba.

DIVISIÓN DEL CONJUNTO DE DATOS

Entrenamiento

80%

Prueba

20%

01

Datos completos

Todo el conjunto de datos disponible

02

División única

Se separa una vez: 80% Train / 20% Test

03

Entrenamiento

El modelo aprende sobre el conjunto de entrenamiento

04

Evaluación

Se mide el desempeño sobre el conjunto de prueba

Ventajas

Muy simple

Muy rápido

Bajo costo computacional

Limitaciones

Depende de una única partición

Alta variabilidad

Puede entregar estimaciones poco representativas

¿Qué es la Validación Cruzada?

Definición

La validación cruzada consiste en repetir varias veces el entrenamiento y la evaluación utilizando diferentes particiones del conjunto de datos.

Objetivo

Su objetivo no es mejorar el modelo, sino obtener una estimación más confiable de su capacidad de generalización.



Múltiples evaluaciones

Se entrena y evalúa el modelo varias veces con distintas particiones



Estimación robusta

El promedio de los resultados es más representativo que una única medición



Reducción de variabilidad

Disminuye el impacto de una partición desfavorable

K-Fold Cross Validation

El conjunto de datos se divide en K partes iguales (folds). En cada iteración, un fold diferente actúa como conjunto de validación mientras los demás se usan para entrenamiento.

Iteración 1

■ Val | ■ Train | ■ Train | ■ Train |
■ Train

Iteración 2

■ Train | ■ Val | ■ Train | ■ Train |
■ Train

Iteración 3

■ Train | ■ Train | ■ Val | ■ Train |
■ Train

Iteración 4

■ Train | ■ Train | ■ Train | ■ Val |
■ Train

Iteración 5

■ Train | ■ Train | ■ Train | ■ Train
| ■ Val

■ Validación ■ Entrenamiento

Cada fold actúa exactamente una vez como conjunto de validación. El resultado final es el promedio de las K evaluaciones.

¿Cómo funciona?



Dividir los datos

Separar el conjunto en K folds de igual tamaño



Evaluar

Medir el desempeño sobre el fold reservado



Repetir el proceso

Completar las K iteraciones



Entrenar el modelo

Usar K-1 folds como conjunto de entrenamiento



Cambiar Fold

Seleccionar el siguiente fold como validación



Calcular el promedio

Promediar los K resultados para la estimación final



El proceso garantiza que cada observación del conjunto de datos sea utilizada exactamente una vez como dato de validación.



Interpretación de resultados

Cada iteración produce un valor de desempeño. El análisis del conjunto de resultados permite evaluar la estabilidad del modelo.

Fold	R ²
1	0.91
2	0.93
3	0.88
4	0.95
5	0.90

0.914

Promedio (R²)

0.024

Desviación estándar



Un promedio alto y una desviación estándar baja indican que el modelo entrega resultados consistentes independientemente de la partición utilizada.



¿Cuántos folds utilizar?

La elección de K afecta el equilibrio entre costo computacional y estabilidad de la estimación.

K	Características
5	Más rápido, menor costo computacional, ligera variabilidad
10	Mayor estabilidad, estimación más confiable, costo moderado
n (LOO)	Leave-One-Out: máxima precisión, muy alto costo computacional



Recomendación práctica

K = 5 y K = 10 son las configuraciones más utilizadas en la práctica



Leave-One-Out

Solo recomendado para conjuntos de datos muy pequeños donde cada observación es valiosa

Hold-Out vs K-Fold

La elección de la técnica depende del tipo de datos y del problema a resolver.

Hold-Out	K-Fold
Una única evaluación	Varias evaluaciones (K iteraciones)
Mayor variabilidad	Mayor estabilidad
Muy rápido	Mayor costo computacional
Menor confiabilidad	Mayor confiabilidad
Depende de la partición	Independiente de la partición
Usa una sola partición para validar	Todas las observaciones actúan una vez como conjunto de validación

“K-Fold proporciona una estimación más robusta del desempeño del modelo. Cuando el tiempo lo permite, es siempre preferible a Hold-Out.”

Laboratorio

En Google Colab utilizaremos el mismo dataset sintético de Salarios vs. Años de Experiencia empleado en el capítulo anterior. Esto permitirá concentrarnos en comprender el funcionamiento de Hold-Out y K-Fold Cross Validation sin incorporar nuevas variables al problema.



Hold-Out

Implementar una única partición Train/Test utilizando el dataset de salarios.



Variabilidad del Hold-Out

Modificar la partición Train/Test y observar cómo cambian las métricas obtenidas.



K-Fold

Aplicar K-Fold Cross Validation con $K = 5$ y $K = 10$ sobre el mismo conjunto de datos.



Resultados por Fold

Visualizar el desempeño obtenido en cada Fold y comparar las distintas evaluaciones.



Promedio

Calcular el promedio de las métricas obtenidas mediante validación cruzada.



Desviación estándar

Analizar la estabilidad del modelo utilizando la variabilidad entre los distintos Folds.

Conclusiones



Partición única

Una única partición puede entregar resultados engañosos y no representativos



K-Fold reduce la dependencia

K-Fold reduce la dependencia de una sola división de los datos



Evaluación, no entrenamiento

La validación cruzada mejora la evaluación del modelo, no su entrenamiento



Herramienta fundamental

Es una herramienta esencial antes de comparar modelos o ajustar hiperparámetros

“

La validación cruzada constituye una práctica esencial para evaluar modelos antes de incorporarlos a un flujo de datos o a un entorno de producción.

”

“

En el laboratorio aplicaremos estos conceptos utilizando Scikit-learn y Google Colab para evaluar la estabilidad y capacidad de generalización de un modelo.

”