

UNIVERSIDAD DE SANTIAGO DE CHILE

Facultad de Administración y Economía

Diplomado en Data Engineer

Evaluación Final

Objetivo

El objetivo de esta evaluación es que cada estudiante desarrolle un proyecto completo de Machine Learning aplicando los conocimientos adquiridos durante el diplomado. El proyecto deberá abordar todas las etapas de un proceso de Ciencia de Datos, desde la comprensión del problema hasta la evaluación e interpretación del modelo obtenido.

Se evaluará principalmente la capacidad de análisis, la correcta aplicación de las técnicas estudiadas y la justificación de las decisiones tomadas durante el desarrollo del proyecto.

Instrucciones Generales

La evaluación es **individual**.

Cada estudiante deberá seleccionar un conjunto de datos público que cumpla con los requisitos establecidos y desarrollar un proyecto completo utilizando **Python** y **scikit-learn** en **Google Colab**.

El notebook deberá ejecutarse correctamente desde la primera hasta la última celda, sin errores.

Requisitos del Dataset

El conjunto de datos deberá cumplir con las siguientes condiciones:

- Ser de acceso público.
- Contener **al menos 100.000 registros**.
- Contener una variable objetivo claramente definida.
- Corresponder a un problema de:

- Regresión, o
- Clasificación.
- No haber sido utilizado durante las clases del diplomado.

Se recomienda obtener el dataset desde repositorios como:

- Kaggle
 - UCI Machine Learning Repository
 - Data.gov
 - Google Dataset Search
 - Portales de Datos Abiertos
-

Desarrollo del Proyecto

El proyecto deberá considerar, como mínimo, las siguientes etapas.

1. Comprensión del Problema (10 puntos)

Describe claramente:

- Problema de negocio.
 - Objetivo del proyecto.
 - Variable objetivo.
 - Tipo de problema de Machine Learning (Regresión o Clasificación).
 - Beneficio esperado para la organización.
-

2. Análisis Exploratorio de Datos (EDA) (20 puntos)

Realice un análisis exploratorio que incluya, como mínimo:

- Dimensiones del dataset.

- Tipos de datos.
- Valores nulos.
- Registros duplicados.
- Estadísticas descriptivas.
- Distribución de la variable objetivo.
- Distribución de variables numéricas.
- Análisis de variables categóricas.
- Matriz de correlación.
- Visualizaciones relevantes.
- Interpretación de los principales resultados obtenidos.

Importante: No se evaluará únicamente la generación de gráficos, sino también la interpretación y análisis de los resultados.

3. Preparación de los Datos (15 puntos)

Realice y justifique las transformaciones necesarias para preparar los datos.

Como mínimo deberá considerar:

- Tratamiento de valores nulos.
- Tratamiento de registros duplicados.
- Tratamiento de valores extremos (cuando corresponda).
- Codificación de variables categóricas.
- Escalamiento de variables (cuando corresponda).
- Ingeniería de características (si aplica).
- División del conjunto de datos en entrenamiento y prueba.

Todas las decisiones deberán estar debidamente justificadas.

4. Reducción de Dimensionalidad (10 puntos)

Aplique al menos una técnica de reducción de dimensionalidad estudiada durante el diplomado.

Por ejemplo:

- PCA (Principal Component Analysis).
- Selección de características (*Feature Selection*).

Explique:

- La técnica utilizada.
 - El criterio para seleccionar el número de componentes o variables.
 - El impacto de la reducción de dimensionalidad sobre el desempeño del modelo.
-

5. Construcción del Modelo (20 puntos)

Construya un modelo utilizando **scikit-learn**.

Se deberá:

- Seleccionar un algoritmo apropiado.
 - Justificar la elección del algoritmo.
 - Entrenar el modelo.
 - Realizar predicciones.
 - Ajustar hiperparámetros cuando corresponda.
-

6. Evaluación del Modelo (15 puntos)

Evaluar el desempeño del modelo utilizando métricas apropiadas.

Para problemas de Regresión

- MAE
- MSE

- RMSE
- R^2

Para problemas de Clasificación

- Accuracy
- Precision
- Recall
- F1-score
- Matriz de Confusión
- Curva ROC (cuando corresponda)

Interpretar los resultados obtenidos.

7. Interpretación del Modelo y Conclusiones (10 puntos)

Analice los resultados obtenidos considerando:

- Variables más importantes.
 - Fortalezas del modelo.
 - Limitaciones del modelo.
 - Posibles mejoras.
 - Aplicaciones prácticas del modelo en un contexto real.
-

Entregables

Cada estudiante deberá entregar:

- Notebook de Google Colab (.ipynb) completamente ejecutado.
- Informe ejecutivo en formato PDF (máximo 10 páginas).
- Enlace oficial del dataset utilizado.

- Archivo del modelo entrenado (.joblib o .pkl), si corresponde.

Criterios de Evaluación

Criterio	Puntaje
Comprensión del problema	10
Análisis Exploratorio de Datos (EDA)	20
Preparación de los datos	15
Reducción de dimensionalidad	10
Construcción del modelo	20
Evaluación del modelo	15
Interpretación y conclusiones	10
Total	100 puntos

Uso de Inteligencia Artificial

Se permite el uso de herramientas de Inteligencia Artificial como apoyo durante el desarrollo del proyecto (por ejemplo, ChatGPT, Gemini, Claude, Copilot, entre otras).

No obstante, **cada estudiante deberá comprender completamente el código desarrollado y ser capaz de explicar y justificar todas las decisiones metodológicas adoptadas.** El uso de estas herramientas no reemplaza la responsabilidad individual sobre el trabajo presentado.

Consideraciones Generales

- Se evaluará especialmente la capacidad de análisis y la correcta aplicación de las técnicas estudiadas durante el diplomado.
- El código deberá estar correctamente documentado y organizado.

- Todas las figuras deberán contar con título y, cuando corresponda, interpretación.
 - El notebook deberá ejecutarse sin errores desde el inicio hasta el final.
 - El informe deberá redactarse utilizando un lenguaje técnico y profesional.
-

Fecha de Entrega

Fecha límite de entrega: 10 de agosto de 2026, hasta las 23:59 horas.

No se aceptarán trabajos entregados fuera del plazo establecido, salvo situaciones debidamente justificadas y autorizadas conforme al reglamento académico vigente.

Forma de Entrega

Los estudiantes deberán enviar la evaluación al siguiente correo electrónico:

eduardo.castillo.r@usach.cl

Asunto del correo:

Evaluación Final – Diplomado Machine Learning – Nombre y Apellido

Archivos adjuntos:

- Apellido_Nombre_EvaluacionFinal.ipynb
 - Apellido_Nombre_Informe.pdf
 - Archivo del modelo (.joblib o .pkl), si corresponde.
-

Recomendaciones

Se recomienda seleccionar un problema relacionado con un área de interés personal o profesional (salud, finanzas, retail, educación, energía, transporte, entre otras). La elección de un problema con contexto de negocio permitirá realizar un análisis más profundo, obtener conclusiones de mayor valor y demostrar una mejor comprensión de las técnicas de Machine Learning aplicadas.